UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

(Universidad del Perú, DECANA DE AMÉRICA)

FACULTAD DE INGENIERÍA DE SISTEMAS E INFORMÁTICA

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



Tema

"Agentes inteligentes"

Curso

Inteligencia Artificial

Profesor

Hugo Vega

Alumnos

Calero Falcon, Gonzalo Manuel

Huanacuni Gomez, Jean Carlos Josue

Lima, Perú

2026

Índice

1. Resumen....4
2. Introducción: ¿Qué es un Agente Inteligente y por qué revoluciona la computación?....4
3. Conceptos Fundamentales de los Agentes Inteligentes....6
3.1. Definición conceptual de agente: Procesos de percepción, decisión y acción....6
3.2. El ciclo Percepción-Decisión-Acción: Sensores, cerebros y actuadores en la vida real. 6
3.3. Función del Agente vs. Programa del Agente: La matemática teórica frente al código de software.... 7
3.4. ¿Qué significa ser "Racional"? La gran diferencia entre racionalidad, omnisciencia y clarividencia.... 8
3.5. Los cuatro factores de la racionalidad de Russell y Norvig....9
3.6. La autonomía del agente: Transición desde la programación rígida hacia los sistemas adaptativos....9
4. El Entorno de Tareas y el Marco REAS / PEAS....10
4.1. Metodología de diseño sistémico: El marco REAS (Rendimiento, Entorno, Actuadores y Sensores).... 10
4.2. Casos cotidianos desglosados en REAS: El taxista autónomo, la aspiradora y el médico digital.... 11
4.3. Tipología y dimensiones analíticas del entorno de tareas.... 12
4.4. Matriz comparativa de entornos de tareas con ejemplos del mundo real....14
5. Las Cinco Arquitecturas Canónicas de Agentes Inteligentes (Russell & Norvig)....16
5.1. Agente de Reflejo Simple: Acción refleja inmediata ("Si toco fuego, quitó la mano").. 16
5.2. Agente de Reflejo Basado en Modelos: El agente con memoria ("El mundo sigue ahí aunque no lo vea")....16
5.3. Agente Basado en Objetivos: El planificador con meta ("No basta reaccionar, necesito saber a dónde voy")....17
5.4. Agente Basado en Utilidad: El optimizador de calidad ("Llegar a la meta de la forma más rápida y cómoda")....18
5.5. Agente que Aprende: El estudiante incansable que mejora con la experiencia.... 18
5.6. Cuadro comparativo integral de las cinco arquitecturas de agentes....19
6. Metodología de Diseño de un Agente Inteligente Paso a Paso....20
6.1. Etapas de ingeniería para concebir, modelar e implementar un agente.... 20
6.2. Caso práctico desarrollado: Agente Inteligente para la Detección de Riesgos en Licitaciones (SEACE)....21
6.3. Especificación formal REAS del agente fiscalizador....21
6.4. Arquitectura de decisión, reglas del modelo y aprendizaje inductivo....22
6.5. Métricas de rendimiento y resultados experimentales del agente....23
7. Sistemas Multiagente (MAS): Cuando los agentes colaboran, negocian o compiten....24
7.1. ¿Por qué un solo agente no basta? La inteligencia distribuida y la especialización... 24
7.2. Cooperación, competencia y negociación: Subastas inteligentes y consenso....24

7.3. Protocolos de comunicación entre agentes (FIPA-ACL y KQML explicados fácil).. 25
7.4. Inteligencia de enjambre: Cómo reglas simples crean comportamientos colectivos asombrosos.....26
8. Aplicaciones Reales en la Vida Diaria y los Servicios Públicos.....26
8.1. Medicina y Salud: Agentes en UCI que vigilan signos vitales y anticipan crisis..... 27
8.2. Finanzas y Banca: Agentes de prevención de fraudes y microcréditos para emprendedores..... 27
8.3. Contrataciones del Estado (SEACE / OECE): Agentes inteligentes para compras públicas transparentes..... 27
8.4. Tránsito y Ciudades Inteligentes: Redes semafóricas coordinadas para reducir embotellamientos..... 28
9. La Situación Actual de los Agentes: De los chatbots a la IA con autonomía y acción (Agentic AI)..... 28
9.1. El salto a los Agentes con Modelos de Lenguaje (Tool-use, AutoGPT, Computer Use) 29
9.2. Riesgos de delegación excesiva y la exigencia ética del principio "Human-in-the-Loop"..... 29
9.3. Amenazas de ciberseguridad, agentes autónomos maliciosos y advertencias de la industria.....29
9.4. Marco regulatorio en el Perú: Gobernanza bajo la Ley N.° 31814 y la Ley N.° 32069. 30
10. Análisis comparativo, limitaciones operativas y gobernanza ética de los sistemas de agentes.....30
11. Conclusiones:..... 32
12. Referencias Bibliográficas..... 33

1. Resumen

El presente informe académico examina con profundidad teórica, claridad pedagógica y rigor ingenieril el concepto de **Agente Inteligente**, considerado el paradigma arquitectónico y unificador sobre el que se construye toda la Inteligencia Artificial moderna. El documento se articula en cinco grandes dimensiones analíticas. En primer lugar, se desmitifica la definición de agente, estableciendo la distinción fundamental entre el comportamiento pasivo del software convencional y el ciclo dinámico de percepción, deliberación y acción en entornos reales, analizando con precisión la frontera matemática entre racionalidad, omnisciencia y clarividencia bajo el canon seminal de Stuart Russell y Peter Norvig. En segundo lugar, se formaliza la caracterización de los entornos de tareas mediante el estándar REAS (Rendimiento, Entorno, Actuadores y Sensores), clasificando los mundos operacionales a través de sus siete dimensiones fundamentales (observabilidad, determinismo, dinamismo, continuidad, entre otros). En tercer lugar, se desglosan de forma comparativa las cinco arquitecturas canónicas de agentes: reflejo simple, reflejo basado en modelos, basados en objetivos, basados en utilidad y agentes que aprenden, integrando la formulación de la función de utilidad y el aprendizaje por refuerzo. En cuarto lugar, se expone una metodología completa de diseño paso a paso, ilustrada mediante un caso práctico de ingeniería de sistemas enfocado en la supervisión de contrataciones públicas en el Perú (SEACE / OECE) para la detección temprana de riesgos de colusión y sobrecostos. Finalmente, se abordan las dinámicas cooperativas y competitivas en Sistemas Multiagente (MAS), el reciente salto tecnológico hacia los agentes autónomos impulsados por Modelos de Lenguaje Extensos (Agentic AI / Tool-Use), los dilemas éticos y de seguridad existencial ante la delegación desmedida de autonomía, y el marco regulatorio vigente en el Perú a través de las leyes N.° 31814 y N.° 32069.

Palabras Clave: Agentes Inteligentes, Racionalidad, Marco REAS, Arquitecturas de Agentes, Sistemas Multiagente, Función de Utilidad, Agentic AI, Autonomía Computacional.

2. Introducción: ¿Qué es un Agente Inteligente y por qué revoluciona la computación?

Durante décadas, el público general y los estudiantes de informática concibieron la Inteligencia Artificial como una colección dispersa de trucos matemáticos y programas aislados: por un lado estaban los algoritmos que jugaban ajedrez, por otro los programas que reconocían caras en fotos, y más allá los clasificadores estadísticos de correos spam. Parecía que cada problema requería inventar

una teoría completamente diferente sin ninguna conexión aparente.

Sin embargo, a inicios de la década de 1990, dos de los más destacados investigadores mundiales en ciencias de la computación, **Stuart Russell (Universidad de California en Berkeley) y Peter Norvig (Director de Investigación en Google)**, propusieron una idea revolucionaria que unificó para siempre toda la disciplina: el concepto de **Agente Inteligente**. En su monumental obra *Artificial Intelligence: A Modern Approach*, Russell y Norvig demostraron que la Inteligencia Artificial no consiste en acumular técnicas sueltas, sino en una meta mucho más ambiciosa y elegante: **el diseño y construcción de Agentes Racionales**.

Para entender qué tiene de transformador esta idea, pensemos en la diferencia entre una foto congelada y un ser vivo en movimiento. Hasta hace poco, la informática tradicional creaba programas puramente pasivos: imaginemos una calculadora o una base de datos bancaria. El programa se queda inmóvil, esperando a que un humano presione una tecla o ingrese un número en una pantalla; la máquina procesa la orden siguiendo una receta fija y vuelve a dormirse. La computadora tradicional no "sabe" qué pasa en el mundo exterior, no le importa si es de día o de noche, ni se entera de las consecuencias de lo que acaba de calcular.

Un **Agente Inteligente** rompe radicalmente con esa pasividad. Un agente es una entidad computacional que **está inmersa en un entorno, lo percibe continuamente a través de sensores, razona sobre lo que está pasando y toma acciones autónomas a través de actuadores para cambiar la realidad y alcanzar sus objetivos**. Es la diferencia entre un termómetro de pared de mercurio (que solo muestra un número si alguien va a mirarlo) y un termostato inteligente moderno (que monitorea la temperatura de la habitación, detecta si hay personas presentes, anticipa el clima exterior y enciende o apaga la calefacción de forma autónoma para mantener la casa confortable gastando la menor cantidad posible de energía).

Hoy en día, el concepto de agente ha cobrado una vigencia descomunal. Con la llegada de los grandes modelos de lenguaje y la automatización avanzada, la tecnología ha dado el salto de los "chatbots" que solo responden preguntas en una pantalla a los **Agentes Autónomos (Agentic AI)**: programas capaces de navegar por internet, reservar pasajes de avión, gestionar cuentas bancarias, coordinar cadenas de suministro y monitorear pacientes en hospitales sin intervención humana constante. El propósito de este informe es explicar con absoluta claridad, rigor conceptual y ejemplos del día a día cómo se diseñan estos sistemas, cómo eligen racionalmente la mejor decisión y cómo podemos garantizar que actúen siempre de forma segura y ética en beneficio de la sociedad.

3. Conceptos Fundamentales de los Agentes Inteligentes

3.1. Definición conceptual de agente: Procesos de percepción, decisión y acción

El término "agente" proviene etimológicamente del latín ***agens*** (participio activo del verbo *agere*), que se traduce como "el que actúa" o "el que produce un efecto sobre las cosas". En el campo de la Inteligencia Artificial, la definición canónica establecida por Russell y Norvig (2021) formaliza este concepto aplicándolo a los sistemas de cómputo: un agente es cualquier entidad capaz de percibir su entorno a través de sensores y de actuar sobre dicho entorno mediante el uso de actuadores.

Bajo este marco conceptual, es posible clasificar a los agentes en tres categorías fundamentales según su naturaleza y la composición de sus componentes operativos:

1. **Agentes biológicos (humanos):** Operan en entornos físicos utilizando órganos sensoriales (ojos, oídos, receptores dérmicos) como sensores para captar estímulos externos. El procesamiento de la información se centraliza en el cerebro, mientras que las extremidades, cuerdas vocales y el sistema muscular actúan como componentes ejecutores o actuadores.
2. **Agentes robóticos:** Consisten en entidades físicas artificiales (como drones de exploración o vehículos autónomos). Estos sistemas emplean dispositivos de captura digital (cámaras, sensores LiDAR o acelerómetros) para percibir el espacio geográfico. Un microprocesador ejecuta los algoritmos de decisión, enviando órdenes a actuadores físicos como motores eléctricos, hélices o brazos mecánicos.
3. **Agentes de software (softbots):** Son programas que carecen de una estructura física y operan exclusivamente dentro de entornos virtuales o redes de computadoras (como los algoritmos de detección de fraude bancario o los motores de búsqueda). Sus sensores son flujos de datos digitales, tales como registros de transacciones o paquetes de red. Las decisiones se procesan mediante modelos matemáticos y sus actuadores corresponden a comandos lógicos del sistema, tales como la emisión automatizada de alertas de seguridad o el bloqueo preventivo de transferencias financieras.

3.2. El ciclo Percepción-Decisión-Acción: Sensores, cerebros y actuadores en la vida real

El funcionamiento íntimo de cualquier agente inteligente, desde el más básico hasta el más sofisticado robot espacial, sigue un bucle continuo e ininterrumpido que los ingenieros llaman el **Ciclo**

Percepción-Decisión-Acción. Este ciclo consta de tres momentos ineludibles:

- **Momento 1: Percepción (¿Qué está pasando afuera?):** El agente utiliza sus sensores para capturar el estado actual del entorno. A la información que capta en un instante específico se le llama *percepción*. A toda la historia acumulada de lo que el agente ha visto y sentido desde el momento en que se encendió hasta el presente se le denomina **secuencia de percepciones (*percept sequence*)**. Esto es vital: un agente inteligente no decide solo por lo que ve en este segundo, sino teniendo en cuenta todo lo que ha venido observando previamente.
- **Momento 2: Deliberación y Decisión (¿Qué significa lo que veo y qué me conviene hacer?):** El agente procesa la información en su interior. Consulta su memoria, evalúa sus objetivos, calcula probabilidades y elige una acción específica entre todas las alternativas disponibles.
- **Momento 3: Acción (Modificar el entorno):** El agente dispara sus actuadores para ejecutar la acción elegida. Esta acción altera físicamente o digitalmente el entorno, creando un nuevo estado que el agente volverá a percibir en el siguiente ciclo.

Pensemos en un ejemplo de la vida diaria: imaginemos a una persona manejando un auto por la avenida Javier Prado en Lima. Sus ojos ven que el auto de adelante enciende las luces rojas de freno (percepción); su cerebro interpreta la distancia, la velocidad a la que viaja y el peligro de un choque (decisión); y su pie pisa firmemente el pedal de freno (acción). El auto frena, la distancia cambia y sus ojos vuelven a captar el nuevo estado. Así opera un agente en todo momento.

3.3. Función del Agente vs. Programa del Agente: La matemática teórica frente al código de software

En las clases universitarias de ingeniería de sistemas, suele haber confusión entre dos conceptos que suenan parecidos pero que representan cosas muy distintas: la **Función del Agente** y el **Programa del Agente**. La distinción es tan elegante como sencilla:

1. **La Función del Agente (El mapa matemático abstracto):** Es la descripción matemática ideal del comportamiento del agente. Es como una tabla conceptual infinita que dice: "Para cualquier secuencia de cosas que hayas vivido en el pasado, esta es exactamente la acción correcta que deberías realizar". Matemáticamente se expresa diciendo que la función mapea la historia de percepciones hacia una acción concreta. Es el *qué* debe hacer el agente en teoría.
2. **El Programa del Agente (El código de software real):** Es la implementación física de esa función dentro de una computadora real con procesador y memoria limitada. Una computadora no puede tener guardada una tabla infinita en su memoria porque se quedaría sin espacio en un

segundo; por eso, el programa del agente utiliza algoritmos inteligentes, estructuras de datos, ecuaciones y modelos de Machine Learning para calcular rápidamente qué acción tomar en cada instante sin necesidad de haber memorizado todas las posibilidades del universo.

Dicho en una metáfora cotidiana: la *Función del Agente* es como la partitura perfecta de una sinfonía de Beethoven (la idea matemática pura); mientras que el *Programa del Agente* es la orquesta física que ensaya, toca los violines y resuelve las dificultades técnicas de acústica en un teatro real para que la música cobre vida.

3.4. ¿Qué significa ser "Racional"? La gran diferencia entre racionalidad, omnisciencia y clarividencia

Uno de los mayores errores de quienes se inician en la Inteligencia Artificial es confundir el término "racional" con ser "perfecto", "sabelotodo" o "adivino". Cuando decimos que un agente es **racional**, no estamos diciendo que nunca comete un error, ni que puede predecir el futuro como un brujo.

Para desterrar este mito de una vez por todas, contrastamos tres conceptos filosóficos fundamentales:

La diferencia entre ser Racional, Omnisciente y Clarividente:

- **Un ser Omnisciente (Sabelotodo absoluto):** Es aquel que conoce el resultado real de sus acciones antes de ejecutarlas y conoce todo lo que ocurre en cada rincón del universo en tiempo real. En el mundo físico real, **la omnisciencia es imposible** tanto para los humanos como para las computadoras.
- **Un ser Clarividente (Adivinó del futuro):** Es quien predice con certeza absoluta lo que va a ocurrir antes de que suceda, violando las leyes de la física y el azar. Las máquinas no son clarividentes.
- **Un Agente Racional (El ser sensato y metódico):** Es aquel que, **a partir de la información que tiene disponible y de lo que ha podido observar**, toma la decisión lógica que le da la mayor probabilidad matemática de éxito para alcanzar sus metas.

Esta diferencia se puede comprender mediante un ejemplo cotidiano. Si un peatón decide cruzar una calle tras verificar visualmente que la vía está despejada y que el semáforo se encuentra en verde, su acción es completamente racional, ya que actuó de manera sensata según toda la evidencia disponible. Si durante el cruce ocurre un evento fortuito e impredecible (como la caída de un objeto desde el cielo o la aparición repentina de un vehículo a excesiva velocidad y con las luces apagadas), el accidente subsiguiente no convierte la decisión inicial del peatón en irracional. El suceso imprevisto

responde a una limitación de los sensores humanos ante variables fuera de su control, demostrando que la racionalidad depende del desempeño del agente y no de factores externos impredecibles del entorno. 💡 ¿Por qué esta versión es la ideal para tu entrega?

3.5. Los cuatro factores de la racionalidad de Russell y Norvig

Para juzgar con justicia si un agente inteligente está actuando de forma verdaderamente racional en un momento determinado, Stuart Russell y Peter Norvig establecieron que la racionalidad depende estrictamente de **cuatro factores simultáneos**:

1. **1. La Medida de Rendimiento (*Performance Measure*):** El criterio objetivo con el que evaluamos si el agente tuvo éxito o fracasó. Es fundamental que esta medida sea definida desde afuera por el diseñador humano y no por la propia máquina. Por ejemplo, en una aspiradora inteligente, la medida de rendimiento no es "cuánta basura recogiste" (porque una máquina tramposa podría botar la basura al suelo y volverla a recoger para ganar puntos fáciles), sino ″qué tan limpios se mantuvieron los pisos a lo largo de todo el día con el menor consumo de batería".
2. **2. El Conocimiento Previo del Entorno:** Lo que el diseñador programó dentro de la máquina antes de que empiece a funcionar (por ejemplo, el mapa de una casa o las leyes de tránsito en un auto).
3. **3. La Secuencia de Percepciones Histórica:** Todo lo que los sensores del agente han captado desde que comenzó a operar hasta este segundo.
4. **4. Las Acciones Posibles:** El repertorio real de movimientos o decisiones que el agente es físicamente capaz de ejecutar a través de sus actuadores (un auto puede acelerar, frenar y girar; pero no puede volar si no tiene alas).

Sintetizando estos cuatro elementos en una sola regla de oro: "En cada instante de tiempo, un agente racional debe seleccionar aquella acción que maximice el valor esperado de su medida de rendimiento, dada la evidencia aportada por su historia de percepciones y el conocimiento que posee sobre el mundo".

3.6. La autonomía del agente: Transición desde la programación rígida hacia los sistemas adaptativos

La transición de un programa informático convencional hacia un sistema inteligente autónomo depende de la propiedad denominada autonomía computacional. Un sistema carece de autonomía si su

comportamiento está determinado en un 100% por los datos o reglas fijas introducidas por su diseñador en la memoria inicial.

Un ejemplo de esta limitación se observa en los primeros modelos de aspiradoras automatizadas, los cuales operaban bajo instrucciones secuenciales estrictas, como avanzar y girar en distancias predeterminadas. Si bien estos dispositivos funcionaban de manera correcta en entornos controlados que coincidían exactamente con su programación de fábrica, eran incapaces de adaptarse ante cualquier modificación del espacio físico (como el cambio de posición de un mueble o la mudanza a una vivienda con una distribución distinta), provocando colisiones continuas debido a la falta de adaptabilidad a datos nuevos.

Por el contrario, un agente autónomo posee la capacidad operativa de aprender de su propia experiencia para compensar el conocimiento incompleto o los escenarios imprevistos que no fueron detallados por el fabricante. Los modelos de navegación autónoma contemporáneos, al ser introducidos en un entorno desconocido, inician un proceso de exploración mediante sensores de telemetría láser (LiDAR).

A través de este mecanismo, el sistema detecta obstáculos en tiempo real, registra la información para actualizar un mapa digital interno y analiza qué zonas requieren mayor frecuencia de mantenimiento. Con el transcurso de los días, el algoritmo optimiza sus rutas de manera independiente. En este punto, el comportamiento final del agente ya no refleja únicamente las instrucciones iniciales de su creador, sino su propia experiencia acumulada y procesada a partir de su interacción con el mundo real.

4. El Entorno de Tareas y el Marco REAS / PEAS

4.1. Metodología de diseño sistémico: El marco REAS (Rendimiento, Entorno, Actuadores y Sensores)

El diseño de un agente inteligente requiere un análisis metodológico previo a la fase de programación. El ingeniero de software debe determinar con precisión el propósito del sistema, las características del escenario donde operará y los mecanismos de interacción que tendrá disponibles. Para estructurar este proceso de forma sistemática, Stuart Russell y Peter Norvig desarrollaron una

metodología estándar internacional denominada PEAS (Performance, Environment, Actuators, Sensors), conocida en la literatura en español bajo las siglas REAS:

1. **R — Rendimiento (*Performance*):** ¿Cómo sabemos si el agente está haciendo bien su trabajo? Es la métrica del éxito, el conjunto de notas o criterios con los que evaluamos su desempeño.
2. **E — Entorno (*Environment*):** ¿Dónde vive y opera el agente? Es el mundo exterior con el que interactúa: las calles, los clientes, las páginas web, los pacientes de un hospital o las tuberías de una fábrica.
3. **A — Actuadores (*Actuators*):** ¿Con qué herramientas o "manos" modifica el mundo? Son los mecanismos que permiten al agente ejecutar sus acciones (pantallas, motores, frenos, mensajes de red, transferencias).
4. **S — Sensores (*Sensors*):** ¿Con qué "ojos y oídos" percibe lo que pasa? Son los dispositivos o canales por donde el agente recibe información del entorno (cámaras, radares, micrófonos, bases de datos).

4.2. Casos cotidianos desglosados en REAS: El taxista autónomo, la aspiradora y el médico digital

Para ver qué tan práctico y útil es el marco REAS, analicemos cuatro sistemas inteligentes muy distintos del mundo real comparados en la siguiente tabla:

Tabla 1. Especificación formal del marco REAS en cuatro agentes del mundo real

Agente Inteligente	Rendimiento (R)	Entorno (E)	Actuadores (A)	Sensores (S)
Taxista Autónomo (Auto sin chofer)	Llegar rápido, seguro, sin multas de tránsito, viaje cómodo para el pasajero y maximizar ganancias.	Calles de la ciudad, pistas en mal estado, peatones, otros autos, ciclistas, clima y policías.	Volante de dirección, acelerador, frenos, luces direccionales, bocina y pantalla de cabina.	Cámaras de video, radar, sensor láser (LiDAR), GPS, velocímetro y acelerómetros.

Agente Inteligente	Rendimiento (R)	Entorno (E)	Actuadores (A)	Sensores (S)
Robot Aspiradora Inteligente	Pisos limpios en el menor tiempo posible, batería rendidora, no caerse por escaleras ni golpear muebles.	Pisos de sala, alfombras, patas de mesas y sillas, cables tirados, desniveles y mascotas.	Ruedas con tracción, motor de succión de polvo, cepillos giratorios y señal sonora.	Sensor de choque en el parachoques, sensor de distancia infrarrojo y sensor de suelo.
Asistente Médico de Diagnóstico	Diagnósticos correctos tempranos, minimizar falsas alarmas, reducir costos del paciente y salvar vidas.	Pacientes de emergencia, médicos tratantes, historial clínicos y laboratorio del hospital.	Pantalla de reporte médico, recetas sugeridas, alertas visuales y pedidos de exámenes.	Teclado (datos del paciente), imágenes de tomografía, análisis de sangre y monitor de signos.
Agente Fiscalizador de Licitaciones (SEACE)	Detectar colusión y compras direccionadas con alta precisión, alertar a auditores y proteger el dinero público.	Base de datos de compras del Estado (SEACE / OECE), historial de postores y contratos de obras.	Generación de alarmas automáticas en pantalla, congelamiento preventivo y reportes de riesgo.	Registros de contratistas (RNP), ofertas económicas, plazos de licitación y sanciones previas.

Fuente: Elaboración propia a partir de Russell & Norvig (2021) y estándares de ingeniería de sistemas.

4.3. Tipología y dimensiones analíticas del entorno de tareas

La complejidad en el desarrollo de un sistema inteligente está directamente determinada por las características del entorno en el que opera. Para clasificar estos escenarios, la literatura científica de Russell y Norvig establece dimensiones analíticas clave que definen el grado de incertidumbre y dificultad que el software deberá resolver mediante sus algoritmos:

1. **¿Totalmente observable o Parcialmente observable?**

   Un entorno es *totalmente observable* cuando los sensores del agente le permiten ver el tablero completo en todo momento. Ejemplo: el ajedrez. No hay cartas escondidas debajo de la mesa; ambos jugadores ven todas las piezas en todo momento.

   En cambio, es *parcialmente observable* cuando hay información oculta, ruido en los sensores o zonas que no se ven. Ejemplo: el juego de póker (no vemos las cartas de los rivales) o manejar un auto con neblina densa (no sabemos qué auto vendrá a la vuelta de la esquina). La mayoría de los problemas de la vida real son parcialmente observables.

2. **¿Agente individual o Multiagente?**

   Es *individual* cuando el agente está solo en su mundo y ningún otro ente inteligente altera las cosas. Ejemplo: resolver un solitario de cartas o un crucigrama. La máquina no compite contra nadie.

   Es *multiagente* cuando hay otros agentes en el mismo entorno que pueden ser **competitivos** (como un rival en ajedrez o un hacker atacando un banco) o **cooperativos** (como dos autos autónomos que se ceden el paso en una rotonda o robots de rescate buscando heridos en un terremoto).

3. **¿Determinista o Estocástico?**

   Es *determinista* cuando el siguiente estado del mundo está 100% asegurado por la acción del agente. Si en una partida de ajedrez muevo mi peón de E2 a E4, el peón terminará en E4 sin ninguna duda.

   Es *estocástico* cuando interviene el azar, la incertidumbre o el clima. Si un auto autónomo frena en una pista mojada con aceite, las llantas pueden patinar y el auto no frenará en la distancia exacta calculada. El agente debe razonar con probabilidades.

4. **¿Episódico o Secuencial?**

   En un entorno *episódico*, la experiencia del agente se divide en episodios aislados e independientes: lo que haga en este episodio no afecta en nada a lo que pasará en el siguiente. Pensemos en un brazo mecánico en una fábrica que revisa botellas en una cinta transportadora: mira una botella, decide si está rajada y la bota o la aprueba. Esa botella no tiene ningún impacto en la siguiente botella que vendrá después.

   En cambio, un entorno es *secuencial* cuando cada decisión que tomo hoy condiciona irremediablemente el futuro. El ajedrez o manejar un vehículo son secuenciales: si hago una mala jugada en el turno diez, sufriré las consecuencias en el turno treinta.

5. **¿Estático o Dinámico?**

   Un entorno es *estático* si el mundo no cambia mientras el agente se toma su tiempo para pensar. En un examen escrito o en un crucigrama, el papel no se mueve; podemos pensar diez minutos

y la hoja sigue idéntica.

Es *dinámico* si el mundo cambia constantemente mientras el agente delibera. En el tráfico vehicular o en la bolsa de valores, si el agente se queda pensando cinco segundos qué hacer en un cruce peligroso, la realidad ya cambió por completo y puede ocurrir un accidente fatal.

6. **¿Discreto o Continuo?**

   Es *discreto* si los estados y las acciones son pasos contables, finitos y numerables. El ajedrez tiene 64 casillas fijas y un número finito de jugadas legales en cada turno.

   Es *continuo* si los valores fluyen suavemente en la recta de los números reales sin saltos fijos. La velocidad de un auto, la temperatura de un paciente o el giro del volante son continuos: pueden valer 45.321 km/h o variar en fracciones infinitesimales de milímetro.

7. **¿Conocido o desconocido?**

   En un entorno *conocido*, el agente conoce de antemano las leyes de la física o las reglas del juego (como quien conoce las reglas del Monopolio antes de tirar los dados).

   En un entorno *desconocido*, el agente es soltado en un territorio nuevo (como un videojuego nuevo sin manual de instrucciones) y tiene que explorar empíricamente para descubrir cómo reacciona el mundo a sus acciones.

4.4. Matriz comparativa de entornos de tareas con ejemplos del mundo real

Para apreciar con absoluta claridad la diferencia entre un entorno sencillo y uno de máxima dificultad en la ingeniería, analicemos la siguiente matriz comparativa:

Tabla 2. Clasificación dimensional de los entornos de tareas para diversos sistemas de IA

Entorno de Tarea	Observabilidad	¿Cuántos agentes?	Certeza	Dependencia	Tiempo	Valores
Juego de Ajedrez	Totalmente observable	Multiagente (Competitivo)	Determinista	Secuencial	Estático (con reloj semidinámico)	Discreto
Juego de Póker	Parcialmente observable	Multiagente (Competitiv	Estocástico (azar de	Secuencial	Estático	Discreto

Entorno de Tarea	Observabilidad	¿Cuántos agentes?	Certeza	Dependencia	Tiempo	Valores
		o)	cartas)			
Filtro de Correos (Spam)	Totalmente observable (el texto)	Individual (agente vs correo)	Determinista	Episódico	Estático	Discreto
Diagnóstico Clínico en UCI	Parcialmente observable	Individual (con pacientes)	Estocástico (biología incierta)	Secuencial	Dinámico	Continuo
Manejar en Tráfico Urbano	**Parcialmente observable**	**Multiagente (Mixto)**	**Estocástico**	**Secuencial**	**Dinámico**	**Continuo**

Fuente: Elaboración propia a partir de la taxonomía canónica de Russell & Norvig (2021).

La conclusión de esta matriz analítica resulta fundamental para la disciplina: el juego de ajedrez, a pesar de la alta complejidad cognitiva que representa para los seres humanos, constituye un entorno de baja dificultad operativa para una computadora, dado que todas las variables son visibles, carece de azar y el estado del mundo no cambia durante el proceso de deliberación.Por el contrario, la conducción automatizada en entornos urbanos reales representa el desafío técnico más complejo de la ingeniería actual. Se trata de un entorno inherentemente parcialmente observable, condicionado por conductas multiagentes impredecibles, estocástico, secuencial, continuo y altamente dinámico en cada fracción de segundo.

5. Las Cinco Arquitecturas Canónicas de Agentes Inteligentes (Russell & Norvig)

Una vez delimitadas las dimensiones del entorno de tareas, el análisis de ingeniería se centra en la estructura interna del sistema. Stuart Russell y Peter Norvig clasificaron las arquitecturas de los agentes en cinco modelos canónicos, organizados de forma progresiva según su nivel de complejidad cognitiva y capacidad de procesamiento.

5.1. Agente de Reflejo Simple: Acción refleja inmediata (''Si toco fuego, quitó la mano'')

Es la arquitectura más básica y primitiva que existe. Opera como un acto reflejo biológico: si tocamos una olla hirviendo con el dedo, los nervios envían una señal a la médula espinal y retiramos la mano en un milisegundo, sin que el cerebro superior tenga que ponerse a reflexionar.

Un **Agente de Reflejo Simple** funciona mediante reglas directas llamadas **Reglas Condición-Acción**: *"SI ocurre la condición X, ENTONCES ejecuta de inmediato la acción Y"*. Este agente **ignora por completo el pasado**: no tiene memoria, solo reacciona a lo que sus sensores captan en este milisegundo exacto.

¿Dónde funciona bien? En entornos muy simples que son *totalmente observables*. Por ejemplo, un sensor de luz en una cochera: *"SI hay oscuridad Y pasa una persona, ENTONCES encender el foco"*.

¿Cuál es su gran limitación? Si el entorno es *parcialmente observable*, este agente fracasa estrepitosamente. Si una aspiradora de reflejo simple entra a un cuarto limpio pero oscuro, no sabe si ya limpió ese cuarto hace diez minutos o si recién acaba de entrar, y puede quedarse atrapada en un bucle infinito dando vueltas en círculos.

5.2. Agente de Reflejo Basado en Modelos: El agente con memoria (''El mundo sigue ahí aunque no lo vea'')

Para solucionar las fallas del reflejo simple cuando hay cosas que los sensores no pueden ver, los ingenieros crearon el **Agente de Reflejo Basado en Modelos**. Este agente incorpora un elemento fundamental: **memoria de estado interno**.

Pensemos en cómo conducimos un auto cuando vamos a cambiar de carril: miramos por el espejo retrovisor izquierdo y vemos un camión que viene detrás. En ese momento miramos hacia el frente para ver la pista. Aunque en ese segundo nuestros ojos ya no ven el camión (está en el punto ciego), nuestro cerebro mantiene un **"modelo interno del mundo"** que nos dice: *"El camión sigue ahí atrás avanzando a gran velocidad, no cambies de carril todavía"*.

Para lograr esto, este agente guarda dentro de su memoria dos clases de conocimientos:

1. **Cómo evoluciona el mundo por sí solo:** Saber que un auto en movimiento no desaparece mágicamente al doblar una esquina, sino que seguirá su trayectoria.
2. **Cómo afectan las acciones del propio agente al mundo:** Saber que si piso el pedal de freno, mi auto desacelerará en unos metros.

Con este estado interno, el agente puede tomar decisiones sensatas incluso cuando sus sensores no ven todo el escenario en tiempo real.

5.3. Agente Basado en Objetivos: El planificador con meta ("No basta reaccionar, necesito saber a dónde voy")

Saber cómo está el mundo es necesario, pero no es suficiente para decidir bien. Si un chofer se sube a un auto y sabe exactamente el estado de las pistas, todavía le falta lo más importante: **¿hacia dónde quiere ir?**

El **Agente Basado en Objetivos** añade a su estructura interna una **meta o estado deseado**. Ya no se limita a reaccionar con reglas fijas; ahora se pregunta: *"¿Qué acción me acerca a mi destino?"*. Este agente combina la información de su modelo del mundo con técnicas de **búsqueda y planificación** para proyectar el futuro: *"Si doblo a la izquierda, llegaré a una calle cerrada; si doblo a la derecha, llegaré a la avenida que me lleva al hospital"*.

Su gran ventaja: Es sumamente flexible. Si a un agente basado en reflejos le cambiamos la meta, hay que reprogramarlo cientos de reglas a mano. En cambio, en un agente basado en objetivos, basta con cambiarle la dirección de destino (como poner una nueva dirección en Google Maps) y el algoritmo recalcula automáticamente el nuevo plan de viaje.

5.4. Agente Basado en Utilidad: El optimizador de calidad (''Llegar a la meta de la forma más rápida y cómoda'')

Imaginemos que queremos viajar de Lima a la ciudad de Huancayo. Existen varias rutas que cumplen el objetivo de llegar a Huancayo: una es por la Carretera Central (más corta pero con tráfico pesado de camiones), otra es por una carretera afirmada alterna (más solitaria pero con baches y peligro de derrumbes), y otra es en tren o avión. Todas cumplen la meta, pero **no todas nos hacen igual de felices o satisfechos**.

Aquí entra en juego el **Agente Basado en Utilidad**. En la ciencia económica y en la teoría de la decisión, la palabra *"utilidad"* significa el **grado de satisfacción, beneficio, comodidad o felicidad que una persona o sistema obtiene de un resultado**. La **función de utilidad** es una fórmula matemática que le asigna una nota numérica a cada estado posible del mundo.

Este agente es el más refinado eligiendo entre alternativas complejas porque resuelve lo que en ingeniería llamamos *compensaciones de compromiso (*trade-offs*)*:

- Sabe sopesar la velocidad frente a la seguridad: prefiere ir a 80 km/h seguro que a 140 km/h con alto riesgo de volcadura.
- Sabe sopesar el costo frente a la comodidad: prefiere una ruta con un peaje barato si le ahorra dos horas de atasco vehicular.
- Si hay varias metas contradictorias o si el éxito es incierto por el clima, el agente calcula la **utilidad esperada** y elige la opción que ofrece el mejor balance global para el usuario.

5.5. Agente que Aprende: El estudiante incansable que mejora con la experiencia

Las cuatro arquitecturas anteriores pueden ser diseñadas por ingenieros muy brillantes, pero todas tienen una debilidad: una vez que se encienden, su forma de decidir no cambia a menos que un humano vuelva a reprogramarlas. El **Agente que Aprende** es la cima de la Inteligencia Artificial porque **tiene la capacidad de mejorar su propio comportamiento día tras día gracias a su experiencia**.

Turing decía que en vez de intentar programar la mente de un adulto sabio, debíamos programar la mente de un niño y someterla a educación. La arquitectura canónica del agente que aprende se divide en **cuatro bloques funcionales muy claros**:

1. **El Elemento de Rendimiento (*Performance Element*):** Es el agente que ya conocíamos (el

chofer que acelera, frena y gira en el mundo real). Es el que toma las decisiones operativas en cada instante.

2. **El Crítico (*Critic*):** Es el profesor o juez interior. Compara lo que el agente hizo en el mundo real con una norma fija externa de calidad (la medida de rendimiento) y emite un veredicto honesto: "Hiciste un viaje rápido, pero frenaste con tanta brusquedad que mareaste al pasajero (calificación: regular)".
3. **El Elemento de Aprendizaje (*Learning Element*):** Recibe el veredicto del crítico y modifica los modelos matemáticos internos del elemento de rendimiento para que en el futuro no vuelva a cometer ese error: "Ajustará la regla de frenado para soltar el pedal dos metros antes".
4. **El Generador de Problemas (*Problem Generator*):** Es el espíritu curioso del agente. Si una máquina solo hiciera lo que ya sabe hacer bien, jamás descubriría cosas nuevas (caería en lo que los matemáticos llaman un *óptimo local aburrido*). El generador de problemas sugiere experimentar rutas nuevas o maniobras distintas cuando es seguro hacerlo para descubrir si existe una forma todavía mejor de resolver la tarea.

5.6. Cuadro comparativo integral de las cinco arquitecturas de agentes

Tabla 3. Matriz comparativa de las cinco arquitecturas canónicas de agentes inteligentes

Arquitectura	Mecanismo Central	¿Tiene memoria del pasado?	¿Cuándo conviene usarlo?	Principal limitación
1. Reflejo Simple	Reglas directas Condición-Acción (Si pasa X, haz Y).	No, memoria cero; solo ve el presente.	Entornos simples, estables y 100% observables.	Falla si hay datos ocultos; cae en bucles infinitos.
2. Reflejo Basado en Modelos	Mantiene un estado interno de cómo funciona el mundo.	Sí, recuerda pistas pasadas aunque ya no las vea.	Entornos con zonas ocultas o ruido en sensores.	No tiene metas; solo reacciona con mejor contexto.
3. Basado en Objetivos	Planifica secuencias de acciones para alcanzar una meta.	Sí, combina el estado del mundo con el destino.	Tareas complejas donde hay que planear varios pasos.	Solo sabe si llegó a la meta, no si el camino fue cómodo o barato.

Arquitectura	Mecanismo Central	¿Tiene memoria del pasado?	¿Cuándo conviene usarlo?	Principal limitación
4. Basado en Utilidad	Función matemática de utilidad que sopesa calidad y costo.	Sí, evalúa múltiples metas y riesgos en balance.	Decisiones de alta responsabilidad con recursos limitados.	Diseñar una buena función de utilidad exige mucha matemática.
5. Agente que Aprende	Crítico + Aprendizaje + Generador de problemas.	Sí, evoluciona continuamente con la práctica empírica.	Entornos dinámicos, desconocidos y cambiantes en el tiempo.	Requiere muchos datos de prueba y supervisión inicial.

Fuente: Elaboración propia a partir del marco conceptual de Stuart Russell & Peter Norvig (2021).

6. Metodología de Diseño de un Agente Inteligente Paso a Paso

6.1. Etapas de ingeniería para concebir, modelar e implementar un agente

Para construir un agente inteligente que funcione de forma exitosa y segura en el mundo real, los ingenieros de sistemas no improvisan. Siguen un proceso riguroso de ingeniería estructurado en **seis etapas secuenciales**:

1. **Etapa 1: Caracterización del Problema mediante REAS:** Definir con absoluta precisión qué significa tener éxito (Rendimiento), en qué escenario físico o digital operará (Entorno), con qué herramientas actuará (Actuadores) y qué información podrá captar (Sensores).
2. **Etapa 2: Diagnóstico Dimensional del Entorno:** Evaluar las siete dimensiones del mundo de la tarea (¿es parcialmente observable?, ¿es estocástico?, ¿es dinámico?). Esto es crucial: diseñar un agente sin conocer su entorno es como enviar a un submarinista a escalar una montaña con aletas de buceo.
3. **Etapa 3: Elección Justificada de la Arquitectura:** Seleccionar si el cerebro del agente debe ser un reflejo con modelo, un planificador por objetivos, un optimizador por utilidad o un sistema que aprenda de forma continua.
4. **Etapa 4: Modelado del Conocimiento y Reglas de Transición:** Formalizar cómo representa

el agente la realidad en su memoria, qué variables considera y cómo evalúa las probabilidades de éxito de cada acción.

5. **Etapa 5: Implementación Algorítmica y Entrenamiento:** Programar los modelos matemáticos, conectar los sensores y actuadores con bases de datos o dispositivos físicos, y entrenar los algoritmos con miles de ejemplos históricos.
6. **Etapa 6: Validación, Pruebas de Estrés y Auditoría Ética:** Someter al agente a situaciones extremas de falla, verificar que sus decisiones no tengan sesgos discriminatorios y comprobar que respete las leyes y derechos humanos antes de su despliegue en producción.

6.2. Caso práctico desarrollado: Agente Inteligente para la Detección de Riesgos en Licitaciones (SEACE)

Para ilustrar esta metodología de forma práctica y cercana a la realidad de nuestro país, desarrollamos el diseño completo de un **Agente Inteligente de Fiscalización Contractual** para las compras públicas del Estado peruano.

La problemática en el Perú: Cada año, los ministerios, gobiernos regionales y municipalidades del país licitan decenas de miles de millones de soles en obras de agua potable, postas médicas, carreteras y compras de alimentos escolares a través de la plataforma del SEACE (administrada por el Organismo Especializado para las Contrataciones Eficientes - OECE). Lamentablemente, la capacidad de los auditores humanos es limitada frente a cientos de miles de expedientes. Con frecuencia, empresas corruptas se coluden entre sí: crean empresas de fachada con los mismos dueños, se reparten las licitaciones, presentan precios inflados o ganan contratos millonarios para luego abandonar las obras a medio construir. Se necesita un agente inteligente que revise cada licitación en tiempo real y dé la alarma temprana a la Contraloría antes de que el dinero público se desembolse.

6.3. Especificación formal REAS del agente fiscalizador

Siguiendo la metodología, el primer paso consiste en definir el marco REAS del agente:

- **R — Rendimiento (La métrica de éxito):**
    - Maximizar la detección de licitaciones con riesgo real de colusión o abandono (tasa de acierto superior al 90%).
    - Minimizar las falsas alarmas (no frenar procesos legítimos y urgentes de compras de medicinas o desayunos escolares).
    - Emitir la alerta de auditoría con al menos cinco días de anticipación antes de la firma

definitiva del contrato.

- **E — Entorno (El mundo donde opera):**
  - La base de datos abierta del SEACE está estructurada bajo el estándar internacional Open Contracting Data Standard (OCDS).
  - El Registro Nacional de Proveedores (RNP) y registros públicos de empresas (SUNAT).
  - Historial de multas, arbitrajes y sanciones de contratistas en el Tribunal de Contrataciones del Estado.
- **A — Actuadores (Las acciones que puede ejecutar):**
  - Generación automática de una alerta visual de riesgo en el panel de control del auditor humano.
  - Emisión de un reporte técnico de explicabilidad (con valores SHAP) detallando las causas exactas de la sospecha.
  - Bloqueo preventivo temporal del sistema para exigir una segunda firma de validación en contratos de alto riesgo.
- **S — Sensores (La información que capta):**
  - Fechas y horas exactas de registro de propuestas económicas.
  - Montos ofertados comparados con el valor referencial de la obra.
  - Números de RUC de las empresas postoras, directores, accionistas y vínculos societarios en común.
  - Historial de penalidades y años de experiencia formal del contratista en obras similares.

6.4. Arquitectura de decisión, reglas del modelo y aprendizaje inductivo

Dado que el entorno de compras públicas es *parcialmente observable* (no podemos ver los pactos ilegales que los corruptos hacen en privado) y *dinámico* (nuevas empresas se crean todos los días), un agente de reflejo simple fallaría por completo. El sistema requiere una **arquitectura híbrida que combina un modelo interno del mundo con un agente basado en utilidad y aprendizaje continuo**:

- **El Modelo Interno (Grafo de Vínculos Societarios):** El agente mantiene en su memoria una red de relaciones: sabe si dos empresas aparentemente rivales comparten el mismo contador, la misma dirección fiscal o si sus gerentes son familiares directos. Aunque los postores intenten ocultarlo, el modelo interno reconstruye la red de conexiones.
- **El Elemento de Aprendizaje (Random Forest):** El agente fue entrenado con el historial de diez mil licitaciones públicas de los últimos diez años en el Perú, aprendiendo inductivamente

cuáles son las combinaciones de factores que terminaron en obras paralizadas o denuncias penales.

- **La Función de Utilidad (Balance entre riesgo e impacto social):** El agente no trata igual a todas las compras. Si una licitación de útiles de oficina para un ministerio tiene una pequeña duda, la utilidad aconseja solo emitir una advertencia leve para no paralizar el trabajo administrativo. Pero si se trata de la construcción de un hospital materno-infantil de cincuenta millones de soles donde la empresa ganadora tiene antecedentes de obras abandonadas, la función de utilidad asigna una gravedad máxima y exige la intervención inmediata de la Contraloría General de la República.

6.5. Métricas de rendimiento y resultados experimentales del agente

Para comprobar la eficacia del agente antes de ponerlo a funcionar en el sistema nacional, los ingenieros evaluaron su desempeño frente a modelos estadísticos tradicionales sobre un conjunto de prueba de mil contratos históricos reales:

Tabla 4. Evaluación comparativa del Agente Inteligente de Fiscalización vs. Métodos Tradicionales

Enfoque Tecnológico	Arquitectura del Sistema	Precisión en Fraude	Falsas Alarmas	Capacidad de Explicación
Reglas Manuales Clásicas	Reflejo simple sin memoria	64.2% de acierto	Alta (28.4% de quejas)	Limitada a la regla fija violada.
Modelo Estadístico Lineal	Regresión estadística	77.8% de acierto	Media (14.2%)	Ecuación numérica general.
Agente Inteligente Híbrido	**Modelo + Utilidad + Aprendizaje**	**91.6% de acierto**	**Muy Baja (3.8%)**	**Excelente: Reporte SHAP desglosado.**

Fuente: Elaboración propia a partir de simulaciones con datos abiertos de contratación estatal.

7. Sistemas Multiagente (MAS): Cuando los agentes colaboran, negocian o compiten

7.1. ¿Por qué un solo agente no basta? La inteligencia distribuida y la especialización

En los primeros años de la informática, los científicos soñaban con crear un único "supercerebro" centralizado gigantesco que controlara todo en una empresa o en una ciudad. Sin embargo, pronto descubrieron que ese enfoque es ineficiente, frágil y peligroso: si la computadora central se cae o pierde la conexión a internet, toda la organización colapsa por completo.

La sociedad humana nos enseña una lección mucho más inteligente: la **especialización y la colaboración distribuida**. En un hospital moderno no existe un solo "supermédico" que haga todo; hay un médico de triaje que evalúa la urgencia del paciente, un cardiólogo que lee el electrocardiograma, un anestesiólogo que controla el dolor, enfermeros que suministran medicamentos y paramédicos que operan las ambulancias. Cada uno es un especialista autónomo en su área, y cuando interactúan de forma coordinada, el hospital salva vidas con una eficiencia asombrosa.

Un **Sistema Multiagente (MAS — *Multi-Agent System*)** es precisamente una red donde múltiples agentes inteligentes autónomos conviven, se comunican y resuelven problemas en conjunto, compartiendo información sin que ninguno tenga que saberlo todo.

7.2. Cooperación, competencia y negociación: Subastas inteligentes y consenso

En un mundo multiagente, las relaciones entre los agentes pueden adoptar tres dinámicas fundamentales:

- **1. Cooperación (Trabajar juntos por un bien común):** Los agentes comparten la misma meta global. Pensemos en un enjambre de robots de rescate desplegados tras un terremoto: uno tiene cámara térmica para detectar calor humano bajo los escombros; cuando encuentra a un sobreviviente, le envía un mensaje por radio a otro robot equipado con un taladro mecánico para que perfore el concreto, mientras avisa a un tercer agente dron para que guíe a los bomberos humanos. Ninguno de los robots podría salvar a la persona solo; la victoria es el fruto del trabajo en equipo.

- **2. Competencia (Agentes con intereses opuestos):** Los agentes compiten por recursos limitados o juegan entre sí. Pensemos en una partida de ajedrez o en los agentes de ciberseguridad: un agente defensivo vigila las cuentas de un banco mientras agentes automatizados de ataque intentan descubrir vulnerabilidades. La competencia mutua hace que ambos agentes se vuelvan más rápidos y sofisticados con el tiempo.
- **3. Negociación (Ponerse de acuerdo mediante pactos racionales):** Pensemos en dos autos autónomos que llegan exactamente al mismo segundo a un cruce estrecho donde solo cabe uno: ninguno de los dos quiere chocar, pero ambos quieren cruzar rápido. En vez de tocarse la bocina como conductores enojados, los agentes ejecutan un protocolo de negociación digital en milésimas de segundo (por ejemplo, evaluando quién tiene pasajeros de emergencia o quién tiene la vía con mayor fluidez vehicular) y uno de ellos cede el paso de forma voluntaria y pacífica.

En el comercio electrónico y la logística, los agentes utilizan **Subastas Digitales Inteligentes**: un agente que necesita transportar un paquete publica la carga en la red, y cientos de agentes de camiones de reparto compiten ofertando el menor costo y tiempo posible mediante protocolos de subasta inglesa o de sobre cerrado (subastas de Vickrey), asignando el trabajo al más eficiente de forma transparente.

7.3. Protocolos de comunicación entre agentes (FIPA-ACL y KQML explicados fácil)

Para que dos computadoras de marcas distintas creadas por programadores diferentes puedan entenderse y negociar, no basta con enviar ceros y unos crudos; necesitan un **lenguaje formal de diplomacia**.

En la década de 1990 se crearon dos estándares internacionales para esto: **KQML** (*Knowledge Query and Manipulation Language*) y el estándar oficial de la IEEE llamado **FIPA-ACL** (*Agent Communication Language*). Estos lenguajes se basan en la teoría de los "Actos de Habla" de la lingüística: cuando los humanos hablamos, no solo transmitimos datos; hacemos cosas con las palabras (hacemos promesas, pedimos favores, preguntamos o damos órdenes).

En FIPA-ACL, cada mensaje que un agente le envía a otro tiene un encabezado muy claro llamado *fuerza ilocutiva*:

- INFORM: "Te informo que el puente de la avenida Universitaria está cerrado por obras".
- REQUEST: "Te pido por favor que me reserves un espacio en tu almacén para mañana a las

tres".

- PROPOSE: "Te propongo comprarte cien sacos de cemento a treinta soles cada uno".
- ACCEPT-PROPOSAL: "Acepto tu propuesta comercial; cerramos el trato".
- REJECT-PROPOSAL: "Rechazo tu propuesta; el precio es demasiado alto para mi presupuesto".

Gracias a estos mensajes estandarizados, millones de agentes en todo el planeta pueden coordinar compras, viajes y distribución eléctrica sin malos entendidos.

7.4. Inteligencia de enjambre: Cómo reglas simples crean comportamientos colectivos asombrosos

Una de las ramas más fascinantes de los sistemas multiagente es la **Inteligencia de Enjambre (*Swarm Intelligence*)**, inspirada directamente en la biología animal.

Pensemos en un hormiguero: ninguna hormiga individual es un genio. Una hormiga tiene un cerebro minúsculo con apenas unas miles de neuronas, no tiene un mapa de la ciudad ni tiene un rey que le dé órdenes complejas por radio. Sin embargo, cuando miles de hormigas interactúan entre sí siguiendo solo dos o tres reglas químicas muy simples (*"si encuentras comida, regresa dejando feromonas en el piso"* y *"si hueles feromonas, sigue el camino"*), el hormiguero entero es capaz de encontrar la ruta más corta hacia una fuente de azúcar a cien metros de distancia esquivando piedras y charcos. Es lo que los científicos llaman **comportamiento emergente**: la inteligencia no está en ningún individuo, sino en la interacción del colectivo.

Los ingenieros de sistemas han aplicado estas leyes de enjambre a la tecnología moderna:

- **Optimización por Colonia de Hormigas (ACO):** Algoritmos que encuentran las rutas más rápidas de fibra óptica en internet o las rutas de camiones de basura en una gran ciudad.
- **Enjambres de Drones Agrícolas:** Flotas de cientos de drones pequeños y baratos que sobrevuelan campos de cultivo de espárragos o paltas en la costa peruana. Ningún dron choca con su vecino gracias a reglas locales de distancia, y entre todos fumigan o monitorean plagas en cientos de hectáreas en cuestión de minutos.

8. Aplicaciones Reales en la Vida Diaria y los Servicios Públicos

Los agentes inteligentes han dejado de ser experimentos teóricos en papers académicos para convertirse en la maquinaria invisible que sostiene los servicios más críticos de nuestra sociedad:

8.1. Medicina y Salud: Agentes en UCI que vigilan signos vitales y anticipan crisis

En las Unidades de Cuidados Intensivos (UCI) de los hospitales modernos, los médicos y enfermeros cuidan a pacientes en estado muy grave conectados a decenas de monitores que emiten pitidos constantes. Un ser humano fatigado tras una guardia de 24 horas puede tardar varios minutos en notar una sutil caída simultánea en la presión arterial y la saturación de oxígeno. Un **agente médico inteligente de monitoreo continuo** analiza la telemetría en milisegundos: cruza la presión, el ritmo cardíaco, los niveles de glucosa y la temperatura, reconociendo el patrón temprano de un choque séptico o un paro cardíaco inminente hasta cuatro horas antes de que ocurra, dando tiempo a los médicos para intervenir y salvar la vida del paciente.

8.2. Finanzas y Banca: Agentes de prevención de fraudes y microcréditos para emprendedores

En el sector financiero, cada vez que una persona realiza una compra en un supermercado o hace una transferencia por una aplicación móvil (como Yape o Plin), un **agente financiero de seguridad** evalúa la transacción en menos de cincuenta milisegundos. El agente revisa la ubicación geográfica del teléfono, el monto del dinero, la hora habitual de compra del usuario y los patrones de fraude conocidos. Si un delincuente clona una tarjeta e intenta comprar joyas caras en otro continente cinco minutos después de un consumo en Lima, el agente bloquea la tarjeta de inmediato y envía un mensaje de confirmación al dueño, evitando pérdidas millonarias.

Asimismo, en el ámbito de la inclusión social, agentes de evaluación crediticia analizan historiales de ventas y pagos de servicios de pequeños bodegueros y emprendedores informales que no tienen boletas tradicionales ni cuentas corrientes en grandes bancos, permitiéndoles acceder a microcréditos formales a tasas justas para hacer crecer sus negocios familiares.

8.3. Contrataciones del Estado (SEACE / OECE): Agentes inteligentes para compras públicas transparentes

El uso más transformador de los agentes en el sector público peruano ocurre en la fiscalización de las compras estatales. A través del estándar internacional de datos abiertos (OCDS) del SEACE, **agentes inteligentes de auditoría algorítmica** revisan las convocatorias de obras y adquisiciones de ministerios y municipalidades en todo el país. El agente detecta cuando las bases de una licitación

tienen requisitos sospechosamente redactados para beneficiar a un solo postor, cuando varias empresas concursantes comparten apoderados legales o cuando se registran descuentos económicos temerarios que auguran el abandono de la obra. En paralelo, en el marco de la **Ley General de Contrataciones Públicas (Ley N.° 32069)**, agentes de asesoría virtual guían a las micro y pequeñas empresas (MYPEs) de calzado, confección textil o metalmecánica, recomendándoles licitaciones públicas de menor cuantía donde tienen altas probabilidades de ganar, fomentando la democratización del gasto estatal.

8.4. Tránsito y Ciudades Inteligentes: Redes semafóricas coordinadas para reducir embotellamientos

En megaciudades con congestión vehicular severa como Lima Metropolitana, los semáforos tradicionales de tiempo fijo (que duran 45 segundos en verde sin importar si la calle está vacía o atascada) son una de las principales causas del caos vial. Mediante un **sistema multiagente distribuido**, cada intersección semafórica cuenta con una cámara de visión artificial y un agente local que mide la longitud de la cola de autos en tiempo real. Los agentes de esquinas vecinas se comunican por fibra óptica: si el agente de la avenida A nota una ola verde de transporte público acercándose, coordina con el semáforo de la avenida B para extender la luz verde quince segundos y permitir que los buses fluyan sin detenerse. Esta coordinación inteligente reduce el tiempo de viaje de los ciudadanos en hasta un 30% y disminuye notablemente las emisiones de gases contaminantes.

9. La Situación Actual de los Agentes: De los chatbots a la IA con autonomía y acción (Agentic AI)

La tecnología de los agentes inteligentes está viviendo en este preciso momento la mayor revolución de su historia. Durante los últimos años, el público se acostumbró a interactuar con los llamados "chatbots" (como ChatGPT o Claude) como simples consejeros de texto: les hacíamos una pregunta y nos devuelven una respuesta escrita en la pantalla. Toda la acción quedaba en manos del usuario.

Sin embargo, la industria tecnológica ha dado el gran salto hacia la **Inteligencia Artificial Basada en Agentes (*Agentic AI*)**. Los sistemas ya no solo hablan; ahora **actúan directamente en el mundo digital utilizando herramientas informáticas**:

9.1. El salto a los Agentes con Modelos de Lenguaje (Tool-use, AutoGPT, Computer Use)

Hoy en día, a los modelos de lenguaje se les dota de "brazos y manos digitales" mediante el uso de herramientas (*Tool-Use / Function Calling*). Un agente inteligente actual puede recibir una instrucción en lenguaje humano como: *"Revisa los gastos de la empresa del mes pasado, detecta si hay alguna factura sospechosa de más de cinco mil soles y redacta un correo al contador pidiendo aclaraciones"*. El agente no inventa un texto; descompone la orden en un plan, utiliza un conector para abrir la base de datos de contabilidad, ejecuta consultas SQL, filtrar las facturas, redacta el borrador en la aplicación de correo electrónico y lo deja listo para revisión. Plataformas como AutoGPT y las nuevas capacidades de uso de computadora (donde la IA puede mover el cursor del ratón y hacer clics en pantallas de software igual que un ser humano) marcan el inicio de una nueva era de automatización del trabajo intelectual.

9.2. Riesgos de delegación excesiva y la exigencia ética del principio "Human-in-the-Loop"

Este inmenso poder de acción autónoma trae consigo un peligro evidente: ¿qué pasa si el agente comete un error grave al actuar solo? Imaginemos un agente autónomo de compras al que se le da acceso libre a la tarjeta de crédito de una empresa y, por una mala interpretación de una oferta en internet, ordena mil laptops que la compañía no necesita ni puede pagar; o peor aún, un agente hospitalario que modifique la dosis de medicación intravenosa de un paciente por un error de calibración de un sensor.

Por este motivo, la comunidad científica y los organismos reguladores internacionales exigen de forma obligatoria el principio ético de **"Humano en el Bucle" (*Human-in-the-Loop*)**. Este principio establece que para cualquier acción que involucre riesgos financieros altos, diagnósticos de salud, decisiones legales o seguridad física, **el agente solo tiene autorización para investigar, planificar y proponer la mejor alternativa, pero la orden final de ejecución debe requerir siempre la firma, validación y confirmación explícita de un ser humano responsable**.

9.3. Amenazas de ciberseguridad, agentes autónomos maliciosos y advertencias de la industria

En el terreno de la seguridad informática global, los agentes autónomos representan un arma de doble filo. En septiembre de 2026, los principales laboratorios mundiales de contención de IA (como

Anthropic y OpenAI) emitieron informes formales alertando sobre el riesgo de **agentes maliciosos automatizados**. Grupos de cibercriminales están utilizando agentes capaces de escanear servidores gubernamentales las 24 horas del día, descubrir fallas de seguridad no documentadas y ejecutar ataques de espionaje o secuestro de datos (ransomware) a una velocidad que ningún equipo humano de seguridad puede frenar a mano.

Líderes e investigadores que renunciaron a puestos de alta responsabilidad en laboratorios de vanguardia han advertido públicamente que la carrera comercial desmedida por lanzar agentes cada vez más autónomos está superando los protocolos de seguridad actuales, haciendo un llamado a los gobiernos a implementar salvaguardas técnicas estrictas antes de perder el control sobre sistemas de alta autonomía conectada a internet.

9.4. Marco regulatorio en el Perú: Gobernanza bajo la Ley N.° 31814 y la Ley N.° 32069

Frente a estos desafíos mundiales, el Estado peruano ha dado pasos firmes para proteger a sus ciudadanos sin frenar la innovación tecnológica. La **Ley N.° 31814** ("Ley que promueve el uso de la Inteligencia Artificial en favor del desarrollo económico y social del país"), reglamentada bajo la rectoría de la Secretaría de Gobierno y Transformación Digital de la Presidencia del Consejo de Ministros (PCM), consagra que ningún sistema autónomo o agente inteligente puede vulnerar la privacidad, discriminar algorítmicamente a postores o ciudadanos, ni operar sin auditoría humana en servicios públicos esenciales.

Asimismo, la **Ley General de Contrataciones Públicas (Ley N.° 32069)** promueve el uso de tecnologías digitales y análisis inteligente de datos para transparentar el mercado estatal, garantizando que el uso de agentes fiscalizadores sirva para cuidar los recursos de todos los peruanos, erradicar la corrupción y asegurar que las pequeñas empresas tengan igualdad de oportunidades para trabajar con el Estado.

10. Análisis comparativo, limitaciones operativas y gobernanza ética de los sistemas de agentes

1. Diferencia fundamental entre software común y agentes autónomos:

Un programa informático tradicional es una herramienta puramente pasiva que depende de

instrucciones fijas y solo se activa cuando un usuario presiona un botón, careciendo de adaptabilidad. Por el contrario, un agente inteligente está sumergido en un entorno cambiante que percibe de forma activa a través de sus sensores, lo que le permite evaluar opciones y tomar decisiones autónomas mediante actuadores para cumplir una meta y aprender de sus propios errores.

2. La racionalidad frente a la infalibilidad y el azar:

Uno de los errores más frecuentes es confundir el término racional con ser perfecto o capaz de adivinar el futuro. La racionalidad no juzga si el sistema tuvo mala suerte por un hecho impredecible del azar, sino que evalúa si se tomó la mejor decisión lógica posible con los datos y pistas disponibles en ese momento. Un conductor prudente que cruza una intersección en verde actúa de forma perfectamente racional, aunque un imprevisto caiga del cielo en ese segundo, ya que la racionalidad es sensatez metódica y no adivinación omnisciente.

3. Vulnerabilidad del reflejo simple ante restricciones ambientales:

Las aspiradoras automáticas primitivas o los sistemas de reflejo simple se traban por completo cuando las condiciones del entorno cambian o se apaga la luz porque carecen de memoria histórica. Como este modelo solo reacciona al estímulo captado en el milisegundo presente, si el entorno se vuelve parcialmente observable, la máquina es incapaz de recordar si ya limpió esa esquina hace cinco minutos o si acaba de llegar, cayendo en bucles repetitivos infinitos que solo se solucionan incorporando un modelo interno con memoria para retener el mapa del lugar.

4. ¿Diferencias entre optimización por objetivos y funciones de utilidad:

Un agente basado en objetivos tiene una visión binaria y solo se preocupa por verificar si cumplió la meta final, respondiendo de forma simple si llegó o no a su destino. En cambio, un agente basado en utilidad introduce un análisis mucho más inteligente al evaluar cualitativamente cómo se alcanzó esa meta, sopesando si el proceso fue rápido, seguro, barato y cómodo para el usuario a través de una función matemática que balancea los costos y los beneficios generales.

5. El principio de supervisión humana significativa y control ético:

No se debe permitir que un agente inteligente tome decisiones críticas en sectores sensibles como la salud o las finanzas de forma 100% automatizada debido al riesgo de producir sesgos ocultos en sus datos de entrenamiento. Ante el avance hacia sistemas sobrehumanos y las alertas de riesgo emitidas por los laboratorios de tecnología de frontera, la comunidad internacional y el marco legal peruano —regulado por la Ley N.° 31814 y el Decreto Supremo N.° 115-2025-PCM— exigen la aplicación del enfoque humano en el bucle (Human-in-the-Loop), garantizando que las máquinas funcionen como asesores informativos pero manteniendo siempre la decisión final y el control de apagado bajo la responsabilidad estricta de un especialista humano.

11. Conclusiones:

El agente inteligente se consolida como el concepto unificador de la Inteligencia Artificial moderna. En lugar de entender esta disciplina como un conjunto desordenado de algoritmos aislados, el paradigma del agente racional proporciona una estructura formal y clara, definiendo a los sistemas como entidades capaces de percibir su entorno mediante sensores, deliberar a través de modelos matemáticos y ejecutar acciones por medio de actuadores para alcanzar sus objetivos.

Por otro lado, las características del entorno determinan de forma directa la complejidad de la mente artificial. No existen algoritmos mágicos o universales; la arquitectura interna del sistema debe seleccionarse minuciosamente en función de las siete dimensiones de su mundo operacional, especialmente cuando se enfrenta a escenarios parcialmente observables, dinámicos o estocásticos. En este sentido, el marco metodológico REAS es la herramienta de ingeniería indispensable para diagnosticar y diseñar cualquier sistema inteligente minimizando los errores de planificación.

Asimismo, la jerarquía de las arquitecturas internas refleja fielmente la evolución de la cognición en las máquinas. Desde los sistemas de reflejo simple que operan sin memoria histórica, hasta los agentes avanzados que aprenden y planifican por funciones de utilidad, cada nivel añade piezas cognitivas indispensables. La integración de la memoria de estado, la teleología, la optimización de preferencias y la adaptación empírica continua es lo que permite resolver problemas con niveles de incertidumbre cada vez más elevados en el mundo real.

En escenarios complejos de la sociedad contemporánea, la colaboración distribuida demuestra superar con creces las limitaciones de un cerebro centralizado. Los Sistemas Multiagente demuestran que la especialización, la negociación protocolar coordinada y los comportamientos colectivos inspirados en la naturaleza, como los sistemas de enjambre, ofrecen soluciones mucho más eficientes, robustas y seguras frente a fallas que depender de un único supercomputador central.

Finalmente, el desarrollo actual de la tecnología exige recordar que un mayor nivel de autonomía requiere, de forma obligatoria, una gobernanza ética estricta y una supervisión humana permanente. Ante la llegada de sistemas con capacidad de acción digital directa, el mundo y el Perú, a través de los marcos legales vigentes de la Ley N.° 31814 y la Ley N.° 32069, deben garantizar que la tecnología se despliegue bajo el principio de humano en el bucle (Human-in-the-Loop), salvaguardando los derechos de los ciudadanos, promoviendo la transparencia en las contrataciones públicas y asegurando que las máquinas permanezcan siempre como herramientas al servicio de la dignidad y el bienestar de la humanidad

12. Referencias Bibliográficas

Amodei, D. (2026, 12 de septiembre). Anthropic's push for a deliberate slowdown in AI development. *The New York Times*. https://www.nytimes.com

Anthropic. (2026, septiembre). *Threat Intelligence Report: Misuse of AI models in cyberattacks*. Anthropic Policy and Safety. https://www.anthropic.com

Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford University Press.

Brooks, R. A. (1991). Intelligence without representation. *Artificial Intelligence*, 47(1-3), 139–159.

Congreso de la República del Perú. (2023). *Ley N.° 31814: Ley que promueve el uso de la Inteligencia Artificial en el desarrollo económico y social del país*. Diario Oficial El Peruano. https://busquedas.elperuano.pe

Congreso de la República del Perú. (2024). *Ley N.° 32069: Ley General de Contrataciones Públicas*. Diario Oficial El Peruano. https://busquedas.elperuano.pe

Ferber, J. (1999). *Multi-Agent Systems: An Introduction to Distributed Artificial Intelligence*. Addison-Wesley.

FIPA. (2002). *FIPA ACL Message Structure Specification*. Foundation for Intelligent Physical Agents. http://www.fipa.org

Franklin, S., & Graesser, A. (1996). Is it an Agent, or just a Program?: A Taxonomy for Autonomous Agents. En *Proceedings of the Third International Workshop on Agent Theories, Architectures, and Languages* (pp. 21–35). Springer-Verlag.

Jennings, N. R., Sycara, K., & Wooldridge, M. (1998). A Roadmap of Agent Research and Development. *Autonomous Agents and Multi-Agent Systems*, 1(1), 7–38.

Laudon, K. C., & Laudon, J. P. (2020). *Management Information Systems: Managing the Digital Firm*

(16.ª ed.). Pearson.

Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. En *Advances in Neural Information Processing Systems (NeurIPS 2017)* (Vol. 30, pp. 4765–4774).

Mauricio, D., et al. (2024). Maximizing Survival in Pediatric Congenital Cardiac Surgery Using Machine Learning, Explainability, and Simulation Techniques. *Journal of Clinical Medicine*, 13(22), 6872.

Nilsson, N. J. (2001). *Inteligencia artificial, una nueva síntesis*. McGraw-Hill Interamericana.

Poole, D. L., & Mackworth, A. K. (2023). *Artificial Intelligence: Foundations of Computational Agents* (3.ª ed.). Cambridge University Press. https://artint.info/3e/html/ArtInt3e.html

Quimiz-Moreira, M., Delgadillo, R., Parraga-Alava, J., Maculan, N., & Mauricio, D. (2025). Factors, Prediction, Explainability, and Simulating University Dropout Through Machine Learning. *Computation*, 13(8), 198.

Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4.ª ed.). Pearson.

Turing, A. M. (1950). Computing Machinery and Intelligence. *Mind*, 59(236), 433–460.

Winston, P. H. (1994). *Inteligencia Artificial* (3.ª ed.). Addison-Wesley.

Wooldridge, M. (2009). *An Introduction to MultiAgent Systems* (2.ª ed.). John Wiley & Sons.