INTELIGENCIA ARTIFICIAL · UNMSM · FISI

Aprendizaje automático no supervisado

Clustering de imágenes: representación, K-means y dos artículos Scopus



Integrantes:

- Calero Falcon, Gonzalo Manuel
- Huanacuni Gomez, Jean Carlos Josue

Profesor: Hugo Vega · Lima, 2026

01. Fundamentos
Conceptos y Tareas ML

02. Artículos Scopus
2 Investigaciones Clave

03. Ejemplo Práctico
Demostración K-means

Tres formas de aprender

Modalidad	Información usada	Resultado típico
Supervisado	Entradas + etiquetas objetivo	Predice una clase o valor
No supervisado	Entradas sin variable objetivo	Clusters, componentes, anomalías
Auto-supervisado	Sin etiquetas humanas; la señal se crea de los propios datos	Representaciones (embeddings) reutilizables



Auto-supervisado ≠ clustering
Aprende una representación con una tarea creada de los mismos datos, por ejemplo relacionar dos versiones transformadas de una imagen. Luego esa representación se puede agrupar con K-means (Artículo 2).

Tareas del aprendizaje no supervisado



Clustering

Agrupar observaciones semejantes según una representación y una medida de distancia.

Ej: K-means, jerárquico, DBSCAN



Reducción de dimensión

Representar los datos con menos variables conservando parte de su estructura.

Ej: PCA



Anomalías

Detectar observaciones que se apartan del comportamiento predominante.

Ej: Métodos por densidad o distancia



Representaciones

Obtener vectores que concentran la información relevante de los datos.

Ej: Embeddings de redes neuronales

Representación, escala y similitud



La escala importa

Si edad, ingreso y compras tienen escalas distintas, la variable numéricamente mayor domina la distancia. Por eso se estandariza antes de usar métodos basados en distancia, como K-means.

Píxeles crudos ≠ significado

Pequeños cambios de posición, luz o fondo alteran muchos píxeles. Las CNN aprenden rasgos jerárquicos, de patrones locales a estructuras de mayor nivel, más útiles para agrupar.

K-means: cómo funciona

Paso 1 · Inicialización
Elegir k y centroides iniciales

→

Paso 2 · Asignación
Asignar cada punto al centroide más cercano

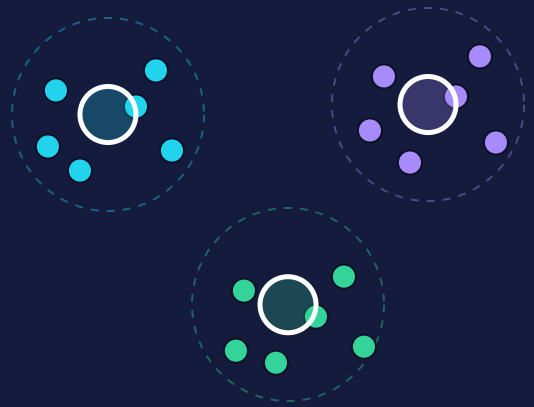
→

Paso 3 · Actualización
Recalcular centroides (media) y repetir

$$J = \sum \|x_i - \mu_{c(i)}\|^2$$

Objetivo de optimización:

- Minimiza la suma de distancias cuadráticas dentro de cada grupo.
- Favorece la creación de clusters compactos y esféricos.
- *Los pasos 2 y 3 se iteran hasta la convergencia.*



Puntos: observaciones · Círculo blanco: centroide μ

Límites de K-means y otros métodos

Limitaciones de K-means

- Hay que fijar k (número de grupos) de antemano
- Sensible a la inicialización de los centroides
- Sensible a valores atípicos que arrastran la media
- No representa bien clusters de formas muy irregulares

Jerárquico

Grupos anidados que se visualizan en un dendrograma; no exige fijar k.

DBSCAN

Clusters en regiones densas; marca el ruido y detecta formas no esféricas.

PCA

No agrupa: reduce la dimensión proyectando sobre las direcciones de máxima varianza.

¿Cómo se evalúa un clustering?

Internas (sin etiquetas)

Métrica	Idea
Silueta	Cohesión vs. separación · mayor es mejor
Davies–Bouldin	Dispersión vs. separación · menor es mejor

Externas (etiquetas solo para evaluar)

Métrica	Idea
NMI	Información compartida con las clases
ARI	Acuerdo entre particiones, corregido por azar
CACC	Mejor correspondencia cluster ↔ clase



Las etiquetas no entrenan

Se ocultan durante el aprendizaje y se usan después solo para medir el resultado. Así el proceso sigue siendo no supervisado, aunque se compare con categorías conocidas.

Embeddings: dos caminos

Preentrenadas (Artículo 1)

- Reutilizan conocimiento visual de ImageNet sin entrenar desde cero
- La arquitectura y la capa elegidas cambian el espacio de agrupamiento
- Cada extractor puede verse como una vista que se combina con otras

Auto-supervisado (Artículo 2)

- Aprende embeddings sin etiquetas humanas con una tarea auto-generada
- Red siamesa entrenada con pares relacionados entre imágenes
- K-means se usa después para medir qué tan agrupable es la representación

Idea clave

El algoritmo que agrupa es una cosa; el espacio donde se agrupa es otra. Mejorar la representación puede pesar más que cambiar de algoritmo.

Artículo 1 | Guérin et al. (2021)

8	5	3	10
datasets (benchmark)	CNN preentrenadas	capas (L1, L2, L3)	extractores (multivista)

Ficha Técnica

Combining pretrained CNN feature extractors to enhance clustering of complex natural images · Neurocomputing 423, 551–571 · DOI 10.1016/j.neucom.2020.10.068

Pregunta Principal de Investigación

1. ¿Cuánto afecta elegir la arquitectura y la capa de una CNN preentrenada al clustering de imágenes?
2. ¿Combinar varias representaciones reduce el riesgo de escoger un extractor inadecuado?

Artículo 1 | Metodología

ETAPA 1 · BENCHMARK (EVALUACIÓN INDIVIDUAL)

PASO 01
8 Datasets
4 tipos de tarea

→

PASO 02
5 CNN × 3 Capas
(L1, L2, L3)

→

PASO 03
K-means +
Aglomerativo

→

EVALUACIÓN
Métrica NMI

ETAPA 2 · MULTIVISTA (FUSIÓN DE REPRESENTACIONES)

PASO 01
10 Extractores
= 10 Vistas complementarias

→

PASO 02
Clustering Multivista
+ Red MVnet / MVEC

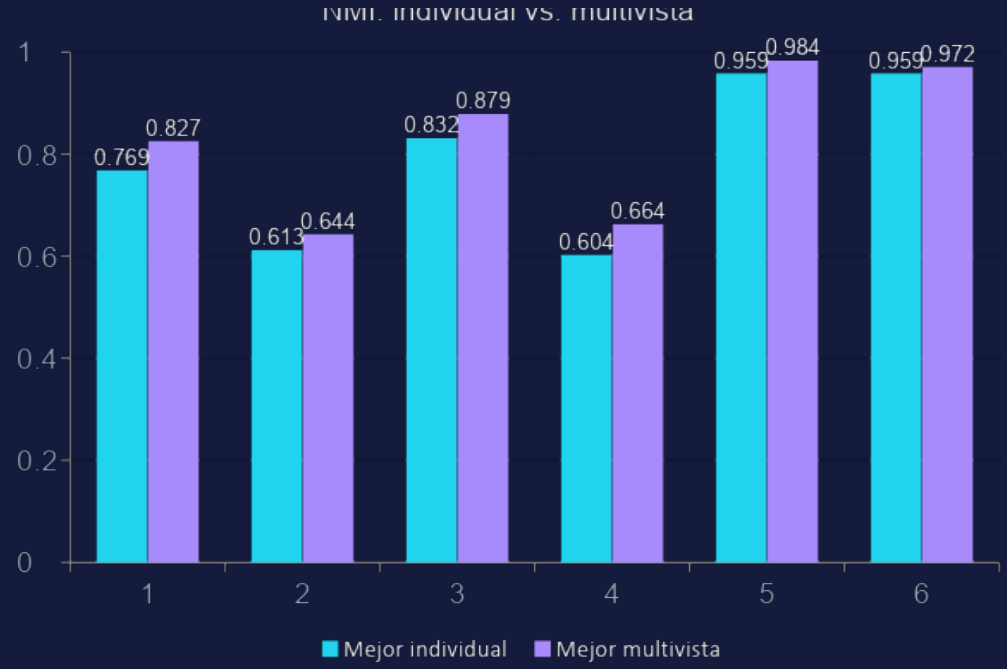
→

EVALUACIÓN
NMI, PUR, ACC

flag **Objetivo principal:** Comprobar cuánto cambia el clustering al variar solo el extractor y verificar si la combinación de vistas logra estabilizarlo.

Artículo 1 | Resultados

COMPARATIVA DE DESEMPEÑO (NMI)



CAPA MÁS EFECTIVA

L3

Capa más estable y útil

RANGO DE IMPACTO

0.521 → 0.633

Birds: ResNet50 → Xception

GANANCIA MULTIVISTA

+0.060

Mejora máxima (Birds)

Artículo 1 · Interpretación y límites

Sin etiquetas no sabes cuál extractor es mejor

La evaluación usa etiquetas conocidas; en un problema exploratorio real no estarían disponibles para decidir qué extractor fue mejor. Por eso es difícil elegir la arquitectura a priori.

Costo computacional

Extraer y combinar varias representaciones exige más recursos; algunos métodos no se pudieron ejecutar en ciertos conjuntos porque 16 GB de RAM no alcanzaron (casos N/A).

Ninguna configuración es universal

MVEC gana en MIT (0.644 vs. 0.591 de MVnet) y MVnetfix en Flowers (0.879 vs. 0.833). El aporte es aprovechar información complementaria, no un método único.

Artículo 2 · Monowar et al. (2022)

8	2–10	18,160	0
plantas evaluadas	clases por planta	imágenes de tomate	etiquetas para entrenar

Ficha

Self-supervised clustering for leaf disease identification · Agriculture 12(6), 814 · DOI 10.3390/agriculture12060814

Problema

Reconocer enfermedades de hojas suele exigir muchas imágenes etiquetadas por especialistas. Los autores buscan aprender representaciones útiles sin etiquetas durante el entrenamiento.

Artículo 2 | Metodología Pipeline del modelo

01 **Imagen** → 02 **Aumentos** de datos → 03 **Pares** can / cannot / mix-link → 04 **Red siamesa** + promedio móvil → 05 **Embedding** → 06 **K-means**

IDEA CLAVE: *Dos vistas relacionadas deben quedar cerca en el embedding y los pares distintos, separados.*

Comparación

Baselines: BYOL, SimSiam y CIKICS (auto-supervisados).

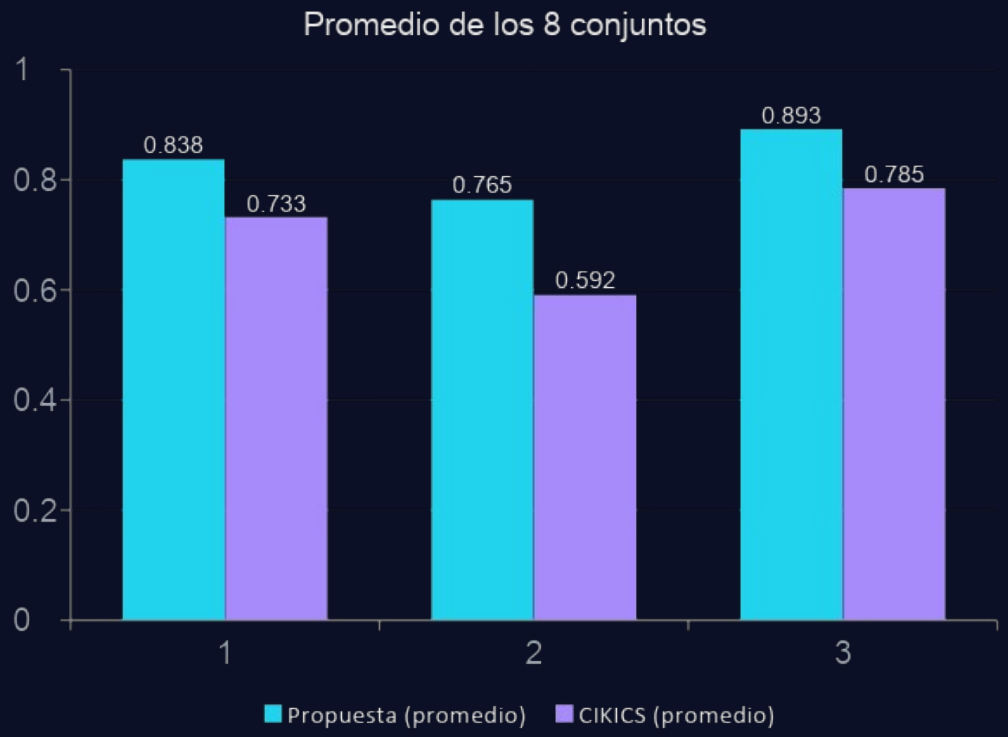
CIKICS es el más competitivo y sirve de referencia para las mejoras promedio.

Métricas

CACC y ARI: Evalúan el embedding directamente con K-means.

ACC: Entrena una capa supervisada sobre embeddings congelados como medida complementaria.

Artículo 2 · Resultados



+0.251

CACC en tomate (0.474→0.725)

0.887 vs 0.273

BYOL manzana: ACC vs. CACC

0.725

tomate (10 clases): el más difícil

Artículo 2 · Interpretación y límites

Método complejo
Necesita una red profunda, aumentos de datos, generación de pares y un entrenamiento específico; es más complejo que un clustering clásico.

Aún necesita etiquetas para evaluar
Las etiquetas no participan en el entrenamiento, pero sí se usan para calcular CACC y ARI. El rendimiento sigue por debajo de alternativas supervisadas.

Datos controlados
PlantVillage tiene imágenes en condiciones relativamente controladas; el desempeño podría cambiar con fondos, cámaras o entornos muy distintos.

UrbanLens - Clustering no supervisado de imágenes urbanas de Lima

FLUJO

30 imágenes
Drive

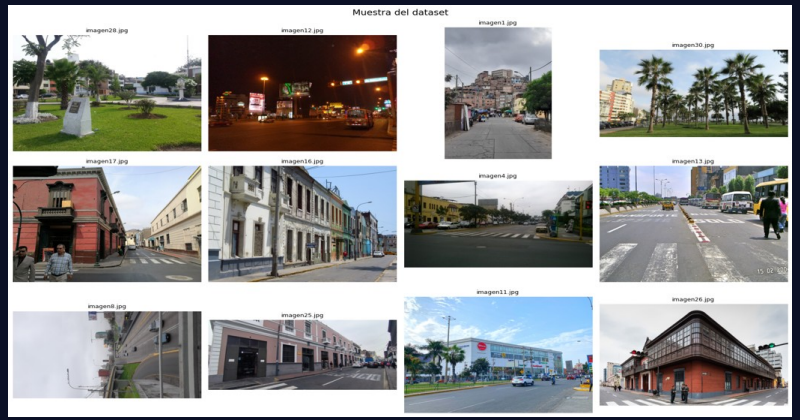
MobileNetV2
1280 features

PCA
26 comp. · 96.09%

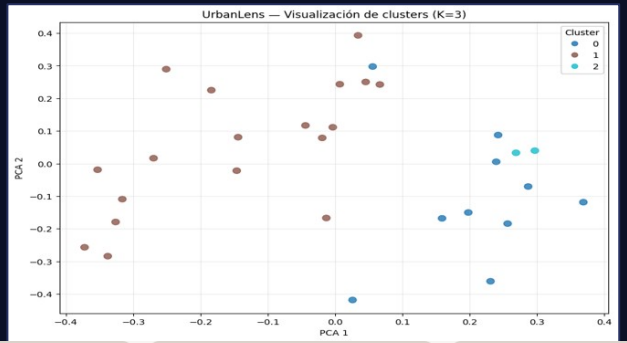
K-Means
K = 3

Interpretación
clusters

Escenas urbanas heterogéneas: vías, arquitectura, tráfico y áreas verdes.



Resultado del agrupamiento



K óptimo
3
mejor Silhouette

Silhouette
0.0666
separación débil

Distribución
10 · 18 · 2
imágenes por cluster

Conclusiones y recomendaciones

Conclusiones

01 K-means no compensa por sí solo una representación deficiente de los datos

02 Capa y arquitectura de la CNN cambian el NMI; combinar vistas suele mejorarlo

03 Embeddings entrenados para agrupar elevan CACC y ARI frente a los baselines

Recomendaciones

01 Justificar y escalar variables o embeddings antes de aplicar clustering

02 No tratar cada cluster como una clase real: revisar qué lo explica

03 Combinar métricas internas y externas, y documentar las configuraciones

Referencias bibliográficas

Bishop, C. M. (2006). Pattern recognition and machine learning. Springer.

Caron, M. et al. (2018). Deep clustering for unsupervised learning of visual features. ECCV, 132–149.

Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. IEEE TPAMI, 1(2), 224–227.

Ester, M. et al. (1996). A density-based algorithm for discovering clusters… KDD-96, 226–231.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press.

Guérin, J. et al. (2021). Combining pretrained CNN feature extractors… Neurocomputing, 423, 551–571.

Jain, A. K. (2010). Data clustering: 50 years beyond K-means. Pattern Recognition Letters, 31(8), 651–666.

Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis. Phil. Trans. R. Soc. A, 374(2065).

Monowar, M. M. et al. (2022). Self-supervised clustering for leaf disease identification. Agriculture, 12(6), 814.

Rousseeuw, P. J. (1987). Silhouettes. J. Comput. Appl. Math., 20, 53–65.

Russell, S. J., & Norvig, P. (2021). Artificial intelligence: A modern approach (4th ed.). Pearson.