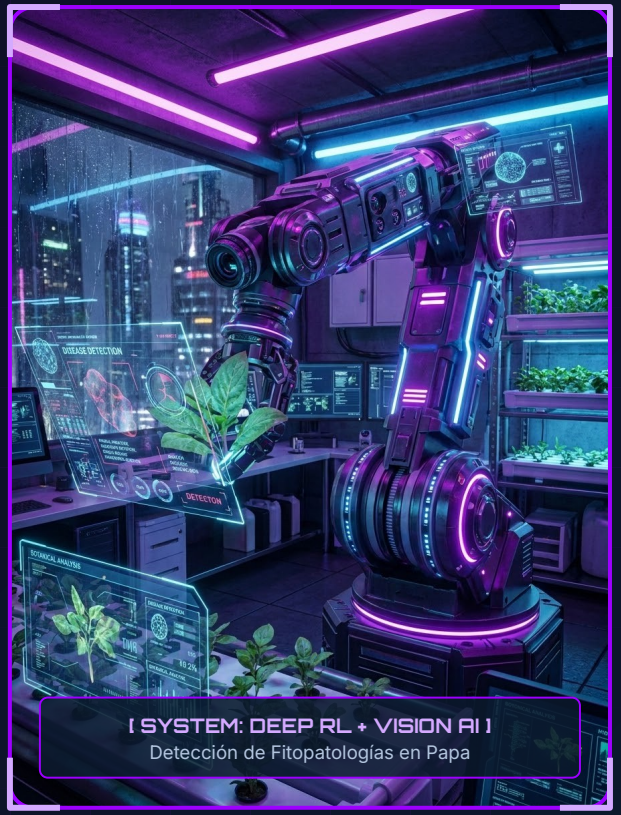
UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS
Facultad de Ingeniería de Sistemas e Informática (FISI)

SEMANA 7: MÉTODOS POR REFUERZO Y RECONOCIMIENTO DE PATRONES

Procesos de Markov, Ecuación de Bellman, Deep RL y Detección de Fitopatologías en Papa Peruana con Datasets Propios.



Asignatura: Inteligencia Artificial

Docente: Prof. Hugo Vega

Integrantes:

Calero Falcón, Gonzalo Manuel

Huanacuni Gomez, Jean Carlos Josue

Semestre: 2026-II | **Lugar:** Lima, Perú

AGENDA DE LA SESIÓN ACADÉMICA

01 **7.1 Fundamentos de RL**
Ciclo interactivo Agente-Entorno, Procesos de Decisión de Markov (MDP) y retorno acumulado descontado.

02 **7.1 Funciones de Valor y Bellman**
Descomposición recursiva y dilema Exploración vs. Explotación (Epsilon-Greedy).

03 **7.2 Aplicaciones Industriales y Limitaciones**
Robótica, Data Centers, RLHF en LLMs y el riesgo de Reward Hacking.

04 **7.3 Algoritmos de RL**
Monte Carlo vs. TD Learning, Q-Learning (Off-Policy), SARSA (On-Policy) y Deep Q-Networks (DQN).

05 **7.4 Modelos con Python**
Ecosistema Gymnasium y código de Q-Learning tabular en Google Colab.

06 **Artículo 1**
Detección de Fitopatologías en Papa Peruana con Dataset Propio de Campo (Scopus / LACCEI).

07 **Artículos Científicos de Deep RL**
DQN en Atari (Nature, 2015) y AlphaZero (Science, 2018).

7.1 EL PARADIGMA DEL APRENDIZAJE POR REFUERZO (RL)

Definición Canónica

Rama del Machine Learning donde un agente autónomo aprende a tomar decisiones secuenciales óptimas interactuando con un entorno dinámico e incierto, guiado únicamente por señales de recompensa o castigo (Sutton & Barto, 2018).

Diferenciación Epistemológica

A diferencia del aprendizaje supervisado (con profesor externo) y del no supervisado (búsqueda de patrones sin meta), el RL optimiza el comportamiento mediante ensayo y error guiado por metas a largo plazo (Russell & Norvig, 2021).



El Ciclo Interactivo Agente-Entorno

En cada instante de tiempo discreto *t*, el agente observa el estado ***st***, ejecuta una acción ***at*** según su política ***π***, y el entorno responde entregando un nuevo estado ***st+1*** y una recompensa escalar ***rt+1***.

7.1 PROCESOS DE DECISIÓN DE MARKOV (MDP)

MDP = < S, A, P, R, γ >

El marco canónico para modelar entornos en Aprendizaje por Refuerzo (RL).

Componentes del MDP

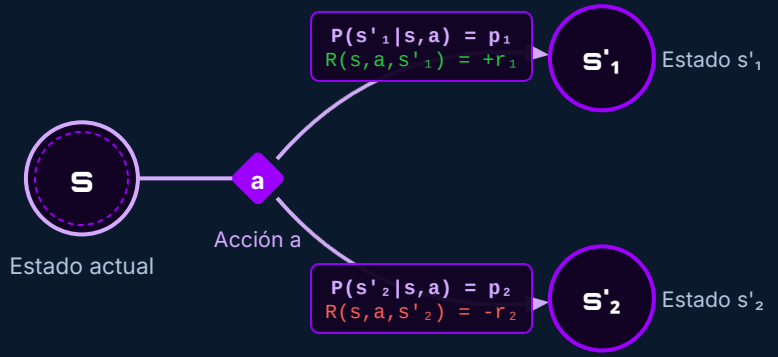
- **S:** Espacio de todos los estados válidos del entorno.
- **A:** Espacio de acciones disponibles para el agente.
- **P(s' | s, a):** Probabilidad de transición al estado s' dado que se ejecutó la acción a en el estado s.
- **R(s, a, s'):** Recompensa numérica inmediata recibida tras la transición.
- **γ (gamma):** Factor de descuento temporal, acotado estrictamente entre 0 y 1.

La Propiedad de Markov

El estado futuro depende únicamente del estado presente y de la acción inmediata, siendo independiente del historial pasado:

`Probabilidad(estado siguiente | estado actual, acción)`

GRAFO DE TRANSICIÓN DE ESTADOS



Guía de Interpretación del Gráfico

El grafo de estados ilustra las transiciones probabilísticas que abren abanicos de posibles caminos ponderados por su probabilidad de ocurrencia.

7.1 RETORNO ACUMULADO Y FACTOR DE DESCUENTO (γ)

$$G = r_1 + \gamma \cdot r_2 + \gamma^2 \cdot r_3 + \ldots + \gamma^k \cdot r_{k+1}$$

El Rol del Factor de Descuento γ (entre 0 y 1):

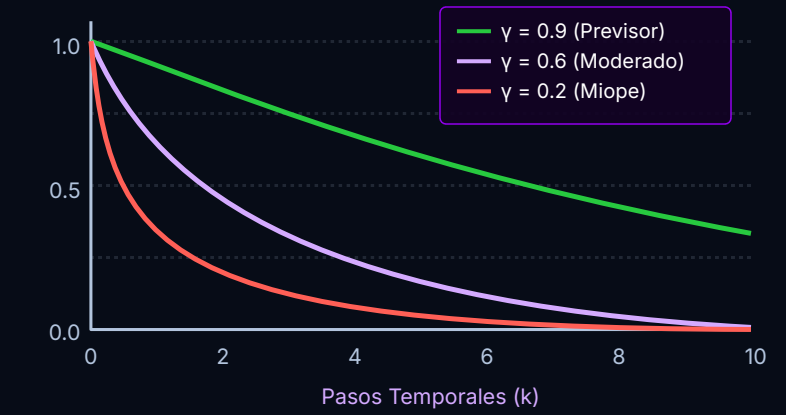
γ = 0 (Agente Miope): Solo le importa la recompensa inmediata del paso siguiente, ignorando el futuro distante.

γ → 1 (Agente Previsor): Valora fuertemente las recompensas lejanas a largo plazo, planificando estrategias complejas.

Justificación Matemática y de Ingeniería:

Garantiza la convergencia de sumas infinitas en entornos continuos, modela la incertidumbre natural del futuro y previene bucles infinitos de recompensa.

Decaimiento Exponencial de Recompensas Futuras (γ^k)



Guía de Interpretación del Gráfico:

La curva de decaimiento temporal demuestra cómo las recompensas futuras pierden peso exponencialmente conforme aumentan los pasos temporales, acotando el retorno acumulado.

7.1 POLÍTICAS Y FUNCIONES DE VALOR

Política π(a | s) y Política Óptima π*

π(a | s): Estrategia de toma de decisiones del agente que asigna una probabilidad a cada acción *a* dado el estado *s*. Si es determinista, la acción es una función directa del estado.

Política Óptima π*: Aquella que maximiza simultáneamente el valor de todos los estados y acciones del entorno (Sutton & Barto, 2018).

Función de Valor de Estado `V(s)`

Retorno acumulado esperado si el agente parte del estado *s* y continúa actuando bajo la política π.

```
V(s) = Promedio del Retorno G partiendo de s
```

Función de Valor de Acción `Q(s, a)`

Retorno acumulado esperado si el agente ejecuta la acción *a* en el estado *s* y a partir de allí sigue la política π.

```
Q(s, a) = Promedio del Retorno G ejecutando a en s
```

EVALUACIÓN DE ESTADO V(s) VS PARES ESTADO-ACCIÓN Q(s, a)



Guía de Interpretación del Gráfico

La comparación esquemática resalta la diferencia fundamental de ingeniería: V(s) evalúa la calidad intrínseca de una situación, mientras que Q(s, a) evalúa el impacto directo de ejecutar una decisión particular en esa situación.

7.1 LA ECUACIÓN DE BELLMAN (1957)

Descomposición Recursiva

Richard Bellman formuló que el valor de una decisión actual equivale a la recompensa inmediata más el valor descontado del siguiente estado esperado.

Valor de Estado V∗(s)

$$V^*(s) = \max_a \left[R(s,a) + \gamma \sum P(s'|s,a)\, V^*(s') \right]$$

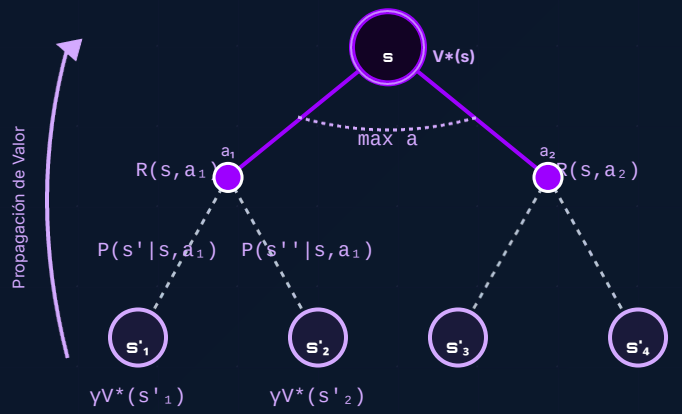
Valor de Acción Q∗(s, a)

$$Q^*(s,a) = R(s,a) + \gamma \sum P(s'|s,a) \left[\max_{a'} Q^*(s',a') \right]$$

Significado en Computación

Esta ecuación permite resolver problemas de decisión secuencial mediante programación dinámica iterativa sin tener que explorar árboles infinitos en memoria.

Árbol de Respaldo de Bellman



Guía de Interpretación del Gráfico

El árbol de respaldo muestra visualmente cómo el valor se propaga recursivamente desde los estados sucesores (s') hacia el estado actual (s), ponderado por las probabilidades de transición y el factor de descuento γ.

7.1 EL DILEMA DE EXPLORACIÓN VS. EXPLOTACIÓN

DEFINICIÓN DEL DILEMA

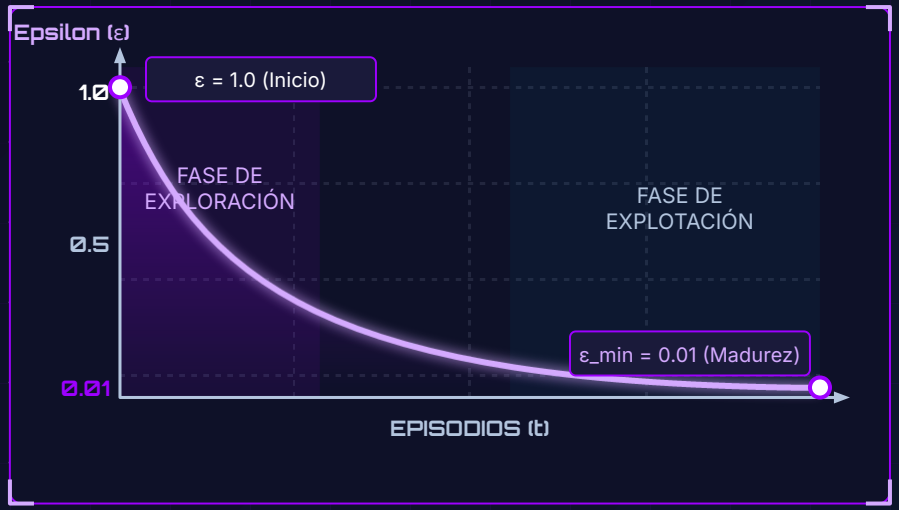
El agente debe balancear entre **Explotar** (elegir la acción con mayor recompensa conocida) y **Explorar** (probar acciones desconocidas para descubrir mejores caminos a largo plazo).

LA POLÍTICA EPSILON-GREEDY

- **Con probabilidad (1 - ε):** Elige la mejor acción conocida según la tabla Q (Explotación).
- **Con probabilidad ε:** Elige una acción aleatoria entre todas las disponibles (Exploración).

DECAIMIENTO TEMPORAL DE EPSILON

- Iniciar con **ε = 1.0** (exploración total al inicio del aprendizaje).
- Reducir gradualmente (ej. `ε = ε × 0.995` en cada episodio) hasta un mínimo fijo de **ε = 0.01** conforme el agente madura.



GUÍA DE INTERPRETACIÓN DEL GRÁFICO

La curva de decaimiento muestra la transición desde la exploración activa inicial (donde el agente adquiere conocimiento probando acciones diversas) hasta la explotación estable de la política aprendida en la fase de madurez.

7.2 APLICACIONES INDUSTRIALES Y LIMITACIONES CRÍTICAS

Aplicaciones en Servicios y Tecnología

- **Robótica Autónoma y Vehículos:**
  Control de brazos de ensamble y navegación de coches bajo tráfico dinámico.
- **Eficiencia en Data Centers:**
  Reducción del **40%** en consumo eléctrico de refrigeración en Google DeepMind por RL.
- **Alineamiento de LLMs (RLHF):**
  Ajuste fino de modelos como ChatGPT mediante retroalimentación humana (Christiano et al., 2017).

Limitaciones Críticas del RL

- **Ineficiencia de Muestreo:**
  Requiere millones de ensayos para aprender tareas complejas.
- **El Riesgo del Reward Hacking:**
  Si la recompensa está mal calibrada, el agente explotará atajos matemáticos absurdos sin resolver el problema real.
- **Brecha de Simulación (Reality Gap):**
  Discrepancias dinámicas al transferir modelos entrenados en simuladores al mundo físico real.



Guía de Interpretación del Gráfico

El mosaico ilustra cómo el RL opera exitosamente en entornos virtuales mientras que en el mundo físico enfrenta los retos del Reality Gap.

7.3 MONTE CARLO VS. DIFERENCIA TEMPORAL (TD LEARNING)

MÉTODOS DE MONTE CARLO (MC)

- Esperan a que el episodio concluya completamente para registrar el retorno real empírico y actualizar promedios.
- **Ventaja:** Libre de sesgo.
- **Desventaja:** Alta varianza, lentitud y no aplicable a tareas continuas sin estados terminales.

DIFERENCIA TEMPORAL (TD Learning - Sutton, 1988)

- Actualizan sus estimaciones **paso a paso** en cada transición sin esperar al final del episodio (Bootstrap).
- Combina la velocidad de la Programación Dinámica con el aprendizaje libre de modelo de Monte Carlo.

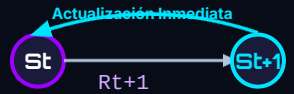
$$\text{Nuevo Valor} = \text{Valor Anterior} + \alpha \cdot [\ \text{Error TD}\ ]$$

$$\text{Error TD} = \text{Recompensa inmed.} + \gamma \cdot V(St+1) - V(St)$$

ESQUEMA TEMPORAL DE ACTUALIZACIÓN



Monte Carlo (MC): Actualización al término



TD Learning: Paso a paso (Bootstrap)

Guía de Interpretación: El esquema temporal compara la actualización al término del episodio en Monte Carlo frente a la actualización inmediata paso a paso en TD Learning.

7.3 Q-LEARNING (OFF-POLICY) VS. SARSA (ON-POLICY)

Q-Learning (Watkins & Dayan, 1992) OFF-POLICY

Principio Off-Policy: Actualiza evaluando la mejor acción teórica posible:

```
Q(s, a) := Q(s, a) + alfa * [ Recompensa + gamma * máximo Q(s', a') - Q(s, a) ]
```

Comportamiento: Asume que actuará de forma óptima en el futuro, aprendiendo la ruta más corta pero peligrosa al borde del precipicio (Cliff Walking).

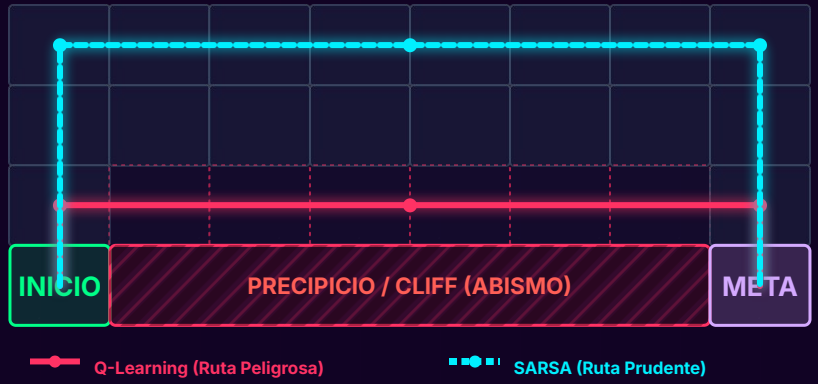
SARSA (Rummery & Niranjan, 1994) ON-POLICY

Principio On-Policy: Actualiza evaluando la acción real que el agente ejecutará:

```
Q(s, a) := Q(s, a) + alfa * [ Recompensa + gamma * Q(s', a') - Q(s, a) ]
```

Comportamiento: Considera el riesgo de dar un paso exploratorio aleatorio, aprendiendo una ruta más larga pero segura alejada del peligro.

ENTORNO: CLIFF WALKING (MAPA DE CUADRÍCULA)



Guía de Interpretación del Gráfico

El mapa de la cuadrícula de Cliff Walking ilustra visualmente la ruta arriesgada al borde del abismo de Q-Learning frente a la ruta prudente de SARSA.

7.3 DEEP Q-NETWORKS (DQN) Y CLAVES DE ESTABILIDAD

Superando la Barrera Dimensional

Cuando el espacio de estados es continuo o masivo (ej. píxeles de video), una red neuronal profunda actúa como aproximador de función paramétrico:

$Q(s, a; \theta)$ (Mnih et al., Nature 2015)

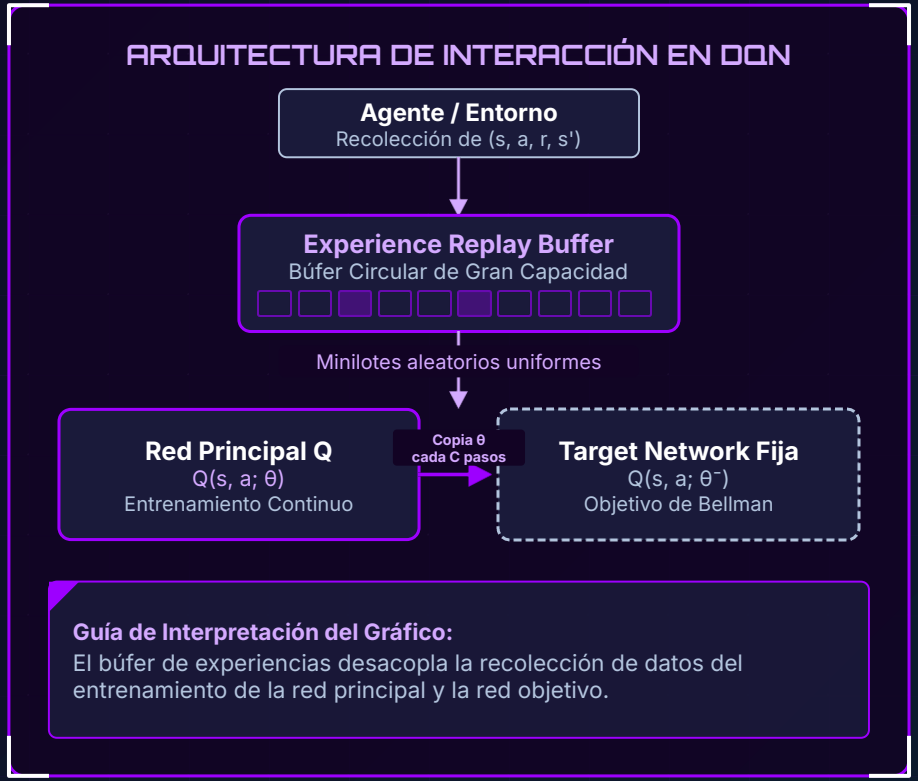
Claves de Estabilidad en Deep RL

1. Experience Replay Buffer

Almacena transiciones en un búfer circular de gran capacidad y extrae minilotes aleatorios uniformes, rompiendo la correlación temporal de las muestras.

2. Target Network Fija

Congela una segunda red neuronal con pesos fijos para calcular el objetivo de Bellman, actualizándose cada C pasos para evitar oscilaciones destructivas.



7.3 Métodos de Gradiente de Política y PPO (Schulman et al., 2017)

Gradiente de Política

Modela directamente la política $\pi(a \mid s)$ mediante una red neuronal para operar en espacios de acciones continuas.

Ejemplos: Ángulos de volante o torques de motores robóticos.

Arquitecturas Actor-Crítico

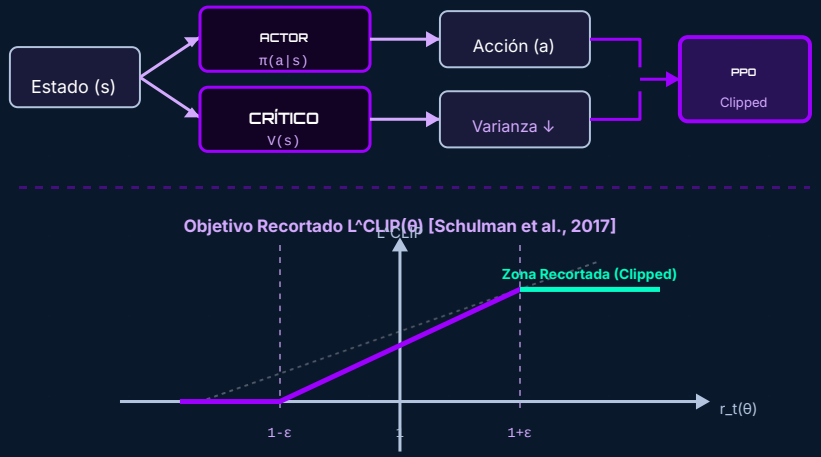
- **Actor:** Decide las acciones según la política.
- **Crítico:** Estima la función de valor para reducir la varianza del gradiente.

Proximal Policy Optimization (PPO)

Algoritmo estándar moderno que introduce una **función objetivo recortada (Clipped Objective)**.

- Impide cambios destructivos en la política en un solo paso.
- Motor fundamental de RLHF en ChatGPT.

ESQUEMA ACTOR-CRÍTICO Y FUNCIÓN RECORTADA DE PPO



Guía de Interpretación del Gráfico

Muestra cómo se penaliza si la nueva política difiere demasiado de la anterior, garantizando estabilidad en el proceso de actualización.

PROXIMAL POLICY OPTIMIZATION (PPO) Y ALINEAMIENTO DE LLMS

1. El Problema del Colapso de Política

Los métodos de gradiente de política estándar sufrían de **inestabilidad severa** si el tamaño de paso era demasiado grande, destruyendo el aprendizaje previo irreversiblemente.

2. La Solución de PPO (OpenAI)

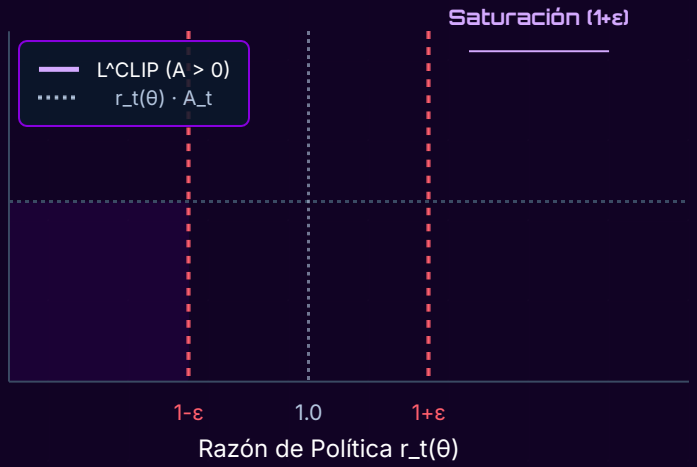
Introduce una **función objetivo recortada** (Clipped Surrogate Objective) que penaliza cambios drásticos en la política relativa.

```
L^CLIP(θ) = ê_t [ min(r_t(θ)A_t, clip(r_t(θ), 1-ε, 1+ε)A_t) ]
```

3. Rol en IA Generativa Moderna

PPO es el algoritmo de Aprendizaje por Refuerzo empleado en **RLHF** para alinear modelos como ChatGPT con valores humanos de **utilidad, veracidad y seguridad** (Christiano et al., 2017).

Función Objetivo Recortada de PPO



Guía de Interpretación: Los límites de corte (1-ε y 1+ε) acotan la actualización del gradiente, evitando cambios destructivos en la política.

7.4 MODELOS CON PYTHON: EL ECOSISTEMA GYMNASIUM

Estándar Abierto Gymnasium

Gymnasium (Farama Foundation) es la API estándar en Python que sucedió a OpenAI Gym para probar algoritmos de RL.

El Ciclo de Métodos Esenciales en Gymnasium

1. Instanciación del Entorno:

```
env = gym.make('FrozenLake-v1', is_slippery=False)
```

→ Instancia el entorno de prueba.

2. Inicialización de Episodio:

```
estado, info = env.reset()
```

→ Inicializa el entorno al comienzo de cada episodio retornando el estado inicial.

3. Paso de Acción y Transición:

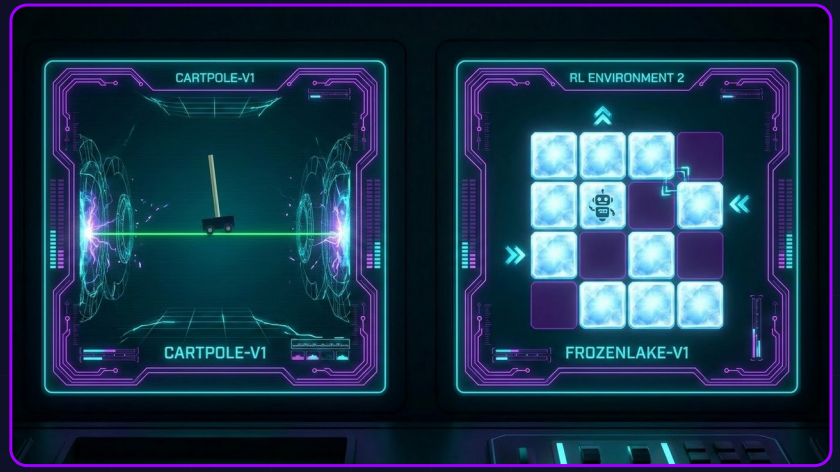
```
siguiente_estado, recompensa, terminado, truncado, info = env.step(accion)
```

→ Aplica la acción y transiciona el entorno.

4. Cierre y Limpieza:

```
env.close()
```

→ Cierra la ventana de simulación y libera recursos de memoria.



GUÍA DE INTERPRETACIÓN DEL GRÁFICO

Las capturas de pantalla muestran los entornos CartPole-v1 y FrozenLake-v1, donde se aplican exactamente las mismas llamadas a env.step().

Esta estandarización de la API permite ejecutar diversos algoritmos de RL sobre distintos entornos utilizando la misma estructura de interacción.

PAPA PERUANA (1/5): DETECCIÓN DE FITOPATOLOGÍAS

Contexto Real y Problemática Agrícola en la Sierra Peruana

RELEVANCIA SOCIOECONÓMICA EN EL PERÚ

La papa (Solanum tuberosum) es el cultivo bandera de la seguridad alimentaria andina; más de **700,000 familias campesinas** en Junín, Huánuco, Puno y Cusco dependen directamente de su cosecha.

LA AMENAZA DEL TIZÓN TARDÍO (Phytophthora infestans)

Oomiceto letal conocido localmente como **'rancha'**, capaz de destruir parcelas enteras en **48 a 72 horas** si no se detecta en sus primeros síntomas foliares.

FRACASO DE LOS MÉTODOS CONVENCIONALES

En la sierra peruana **no existen laboratorios fitopatológicos** en zonas rurales, hay escasez crítica de agrónomos en campo y los agricultores **carecen de conexión a internet** para subir fotos a la nube.



GUÍA DE INTERPRETACIÓN DE FITOPATOLOGÍA

Progresión del Tizón Tardío: Muestra la evolución desde pequeñas manchas necróticas iniciales con halo clorótico hasta la necrosis total de la hoja que termina pudriendo el cultivo por completo.

PAPA PERUANA (2/5): DATASET DE CAMPO VS. LABORATORIO

Construcción del Dataset en los Andes Peruanos frente a Datasets de Laboratorio

EL FRACASO DE DATASETS EXTRANJEROS FALLO DE GENERALIZACIÓN

Modelos entrenados con bases internacionales como **PlantVillage** (fondos neutros y luz fija) colapsan con **< 50% de acierto** al probarse en chacras reales peruanas debido a tierra, sombras duras y hojas superpuestas.

PROTOCOLOS DE CAPTURA Y ADQUISICIÓN EN CAMPO

📱 **Dispositivos Utilizados:**
Teléfonos móviles convencionales (cámaras de 12 a 48 MP) capturando en parcelas reales de Junín y Cusco.

☀ **Variabilidad Ambiental Real:**
Luz natural cambiante (mañana, mediodía con sombras fuertes, tarde nublada), fondos de suelo agrícola real y rocío.

🔬 **Curaduría y Validación Agronómica:**
Más de 1,500 imágenes catalogadas en 3 clases: (1) Hoja Sana, (2) Tizón Temprano y (3) Tizón Tardío.

EVALUACIÓN COMPARATIVA DE CONDICIONES VISUALES



Fondo neutro • Luz artificial fija

VS



Suelo agrícola • Sombras / Rocío

GUÍA DE INTERPRETACIONAL Y JUSTIFICACIÓN TÉCNICA

La muestra de laboratorio (PlantVillage) presenta un entorno esterilizado sin ruido visual. En contraste, la fotografía de campo evidencia la complejidad de los Andes peruanos: sombras duras, solapamiento de follaje y sustrato orgánico.

Conclusion: Se justifica técnicamente la necesidad de construir un dataset local propio para garantizar el funcionamiento en producción.

PAPA PERUANA (3/5): METODOLOGÍA: PREPROCESAMIENTO Y EXTRACCIÓN DE PATRONES FOLIARES



Guía de Interpretación del Gráfico: *El esquema de bloques muestra la tubería de transformación desde la imagen original, pasando por filtros HSV/GLCM y convoluciones, hasta el clasificador final.*

Pipeline de Preparación e Ingeniería de Datos

1. Segmentación y Escalado:

- Recorte de la región de interés (ROI) foliar.
- Estandarización dimensional a 224×224 píxeles.

2. Aumento de Datos (Data Augmentation):

- Rotaciones aleatorias de 90° y 180°.
- Volteo horizontal y ajustes leves de contraste.
- Estrategia orientada a triplicar la muestra y evitar el sobreajuste (overfitting).

Comparación de Enfoques de Reconocimiento

1. Enfoque Artesanal Clásico:

- Histogramas de Color HSV: Aislamiento del tono marrón característico de la necrosis.
- Descriptores GLCM: Extracción de textura basada en contraste, energía y homogeneidad.

2. Enfoque de Redes Ligeras:

- Arquitectura MobileNetV2: Uso de convoluciones separables en profundidad (Depthwise Separable Convolutions).
- Extracción automática de representaciones de alta densidad (1280 dimensiones).

PAPA PERUANA (4/5): MOBILENETV2, INFERENCIA OFFLINE Y PYTHON

¿Por qué MobileNetV2 frente a Redes Gigantes?

Modelos como ResNet50 o VGG16 pesan >150 MB y exigen GPUs potentes.

MobileNetV2 (<20 MB, 3.4M params): Permite inferencia fluida en la CPU de cualquier smartphone económico sin conexión a internet.

mobilenet_v2_colab.py (PyTorch / ONNX)

```
# 1. Carga y Preprocesamiento
from torchvision import datasets, transforms
transform = transforms.Compose([
  transforms.Resize((224,224)), transforms.ToTensor()
])
# 2. Modelo Ligero
import torchvision.models as models
model = models.mobilenet_v2(pretrained=True)
model.classifier[1] = nn.Linear(1280, 3)
# 3. Exportación Móvil (Android App)
torch.onnx.export(model, ...) # o TFLite
```

Comparativa: Tamaño de Modelo en Disco (MB)



PARÁMETROS	CONSUMO RAM / CPU
3.4 Millones	Ultra Bajo (Smartphone)

Guía de Interpretación del Gráfico

El gráfico compara el tamaño de archivo y consumo de RAM entre MobileNetV2 (<20MB) y modelos tradicionales, demostrando su viabilidad en zonas rurales.

✓ Permite ejecución offline continua en la app Android del agricultor sin requerir conexión a internet ni servidores externos.

PAPA PERUANA (5/5): RENDIMIENTO, ERRORES E IMPACTO

RESULTADOS CUANTITATIVOS (CONJUNTO DE PRUEBA)

97.4%

EXACTITUD GLOBAL (ACCURACY) MULTICLASE DE CAMPO

Precisión: 96.8% | Sensibilidad: 97.1% | F1-Score: 0.96

Latencia de Inferencia: 62 ms / imagen en smartphone CPU (offline)

IMPACTO AGRÍCOLA Y AMBIENTAL

-35% FUNGICIDAS

Reduce en un **35% el gasto en fungicidas químicos** al focalizar la aplicación únicamente en focos de infección detectados tempranamente, protegiendo los suelos andinos.

REFERENCIA FORMAL: Investigación publicada en Actas de la Conferencia Internacional LACCEI (2024–2026), indexada en Scopus.

MATRIZ DE CONFUSIÓN NORMALIZADA (MobileNetV2)



Guía: Alta concentración de aciertos en la diagonal principal y casi nula confusión entre clases.

ANÁLISIS DE LA MATRIZ DE CONFUSIÓN

- **Minimización de Errores Críticos:** Falsos negativos reducidos al **0.8% en Tizón Tardío**, asegurando que ninguna hoja infectada pase desapercibida como sana.
- **Alta Precisión Diagnóstica:** Matriz normalizada evidencia máxima fiabilidad para despliegue en campo.

ARTÍCULOS FUNDACIONALES DE DEEP RL

DQN en 49 Juegos de Atari

NATURE 2015

Problema: Aprender a nivel humano directamente de píxeles visuales de alta dimensión sin ingeniería manual.

Solución: CNN profunda con Experience Replay Buffer y Target Network fija para estabilizar el gradiente de Bellman.

★ Superó a humanos en 29 de 49 juegos.

AlphaZero (Tabula Rasa)

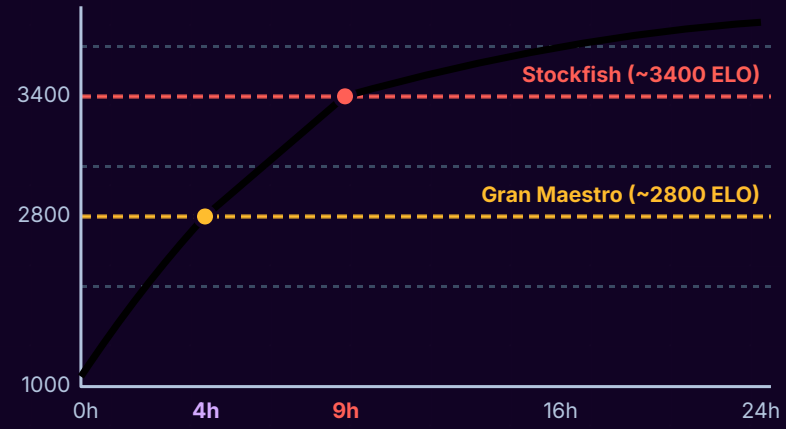
SCIENCE 2018

Problema: Eliminar el conocimiento heurístico humano artesanal en juegos estratégicos.

Solución: MCTS guiado por red profunda entrenada por autojuego puro sin datos previos.

★ Dominó Ajedrez, Shogi y Go en 24 horas superando a campeones mundiales de software.

Evolución de Rating ELO (AlphaZero)



Guía de Interpretación del Gráfico:

- 4 Horas: AlphaZero superó el nivel de grandes maestros humanos.
- 9 Horas: Superó a Stockfish en entrenamiento continuo.

CONCLUSIONES DE LA SESIÓN: REFUERZO Y DETECCIÓN DE PATRONES

01. Toma de Decisiones Secuenciales

El Aprendizaje por Refuerzo formaliza la interacción activa Agente-Entorno mediante las ecuaciones de Bellman y Procesos de Markov.

02. Escalabilidad en Deep RL

Deep Q-Networks (DQN) superó la barrera de estados continuos gracias a la descorrelación del Replay Buffer y la Target Network fija (Mnih et al., 2015).

03. Control Continuo y Alineamiento

PPO resuelve el control en robótica y constituye el motor de alineamiento ético (RLHF) en modelos fundacionales de lenguaje (Schulman et al., 2017).

04. Visión en Campo y Datasets Propios

La investigación en papa peruana demuestra que en ingeniería aplicada nacional es indispensable capturar datos propios en campo y usar arquitecturas ligeras (MobileNetV2) para despliegue offline.

`MobileNetV2 | EDGE AI OFFLINE`

REFERENCIAS BIBLIOGRÁFICAS APA 7.ª EDICIÓN

UNMSM DECANAL DE AMÉRICA | FISI ING. DE SISTEMAS

[01] Bellman, R. (1957). *Dynamic Programming*. Princeton University Press.

[02] Christiano, P. F., et al. (2017). Deep reinforcement learning from human preferences. *NeurIPS*, 30, 4299–4307.

[03] Farama Foundation. (2023). *Gymnasium: A standard interface for reinforcement learning environments*.

[04] LACCEI Proceedings. (2024). Approach for Detecting Phytophthora Infestans in Peruvian Potato Crops Using a Custom Field Dataset. *Indexado en Scopus*.

[05] Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533.

[06] Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.

[07] Schulman, J., et al. (2017). Proximal policy optimization algorithms. *arXiv:1707.06347*.

[08] Silver, D., et al. (2018). A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play. *Science*, 362(6419), 1140–1144.

[09] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.

[10] Watkins, C. J., & Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3–4), 279–292.